

# 基于大模型的多模态风险内容识别平台

作者：陈佳锐，刘沛权，周锐皆，方烨，刘彬慧，曾思航，林依灵

指导老师：李穆，文杰

机构：哈尔滨工业大学（深圳）

## 摘要

随着通信与数字技术的迅速发展，诈骗、谣言等风险内容呈现爆炸性增长态势，成为网络安全治理的重大挑战。同时，深伪技术（Deepfakes）的进步使 AI 换脸、拟声等技术门槛降低，人工智能成为制造多模态风险内容的有效工具。传统识别技术难以应对这些新型风险内容，迫切需要更高效、更精准的风险内容检测手段。

鉴于此背景，本项目构建并实现了一个基于大模型的多模态风险内容识别平台，以对多模态、多类型的风险内容进行自动识别与分析。该平台基于大模型的通用理解能力和模态融合能力，结合多种先进的、不同层次的 deepfake 检测技术，综合使用检索增强生成技术、上下文学习、大模型推理与规划、高效参数微调等多种现代大模型技术，能够全面地识别和分析视频、文本、图像、音频、网页链接和文件等各种模态的风险内容。

平台集成了风险检测、风险识别与分类、风险摘要生成、风险点标注，以及风险分析、相似案例检索、规避风险建议等功能。同时，我们针对不同服务对象（企业用户和个人用户）的需求，将系统平台分为两个模块进行设计。针对前者，我们更加注重对系统平台的效率、稳健性、吞吐量、支持的数据类型是否齐全等指标进行优化提高，以更好地满足企业需求。针对后者，我们在设计与构建时更加注重个性化功能的设计，加入了数字人诈骗检测系统与客制化数字人体验功能。为使系统的部分功能更具易用性，我们还实现了一个简易的、基于 Android 系统的短信风险检测 App。

在搭建平台的同时，我们也尝试在数据集与测评基准方面上推动领域发展。我们使用大语言模型合成了中文短信与对话诈骗风险细粒度分类数据集 [FGRC-SCD](#)，同时基于当前主流的音频生成模型构建了伪造音频检测数据集 [ACG](#)，并在多个任务的数据集上构建了多模态风险内容识别基准 MMRASE，助推多模态风险检测领域的进一步发展。

我们在 MMRASE 基准上对本平台进行了全面测评，该平台在多项任务上均表现出了优异的性能，各项指标均达到了预期数值（见系统测试报告）。

本平台为应对复杂多变的风险内容提供了一个创新性的解决方案。平台具有广阔的应用前景，包括但不限于社交媒体内容审核、新闻媒体真实性检测、电信诈骗预防和自动检测等领域。随着技术的进步和应用场景的不断丰富，未来该平台将集成更多风险检测的相关功能，支持更多数据类型、兼容更多类型的设备，将平台的应用范围拓展到更丰富的场景。我们期待我们的平台、数据集与基准在未来的投入应用中能够发挥预期作用，为构建一个更加安全、健康的网络环境贡献力量。

**关键词：** 风险内容识别 多模态 大语言模型 深度伪造检测 数字人 合成数据集

# 目录

|                            |           |
|----------------------------|-----------|
| <b>一、项目背景和意义</b>           | <b>5</b>  |
| <b>二、项目功能</b>              | <b>7</b>  |
| 2.1 面向企业用户                 | 7         |
| 2.1.1 多模态多粒度风险分类系统         | 8         |
| 2.1.2 风险摘要生成系统             | 9         |
| 2.2 面向个人用户                 | 10        |
| 2.2.1 多模态风险点定位系统           | 10        |
| 2.2.2 风险分析与规避风险建议系统        | 11        |
| 2.2.3 数字人诈骗检测系统与客制化数字人体验   | 11        |
| 2.2.4 Android 短信风险实时判断 App | 12        |
| <b>三、项目功能展示</b>            | <b>13</b> |
| <b>四、技术方案</b>              | <b>16</b> |
| 4.1 项目总体架构                 | 16        |
| 4.1.1 FastAPI              | 17        |
| 4.1.2 Gradio               | 17        |
| 4.2 视频检测                   | 18        |
| 4.2.1 视频内容风险检测             | 19        |
| 4.2.2 视频内容伪造检测             | 19        |
| 4.3 图像检测                   | 20        |
| 4.3.1 伪造图像检测               | 20        |
| 4.3.2 换脸图像检测               | 21        |
| 4.3.3 色情图像检测               | 21        |
| 4.3.4 文本图像检测               | 21        |
| 4.4 音频检测                   | 22        |
| 4.4.1 音频风险检测               | 22        |
| 4.4.2 音频伪造检测               | 22        |
| 4.5 文本检测                   | 23        |
| 4.5.1 两层次文本风险分类            | 23        |
| 4.5.2 文本风险点抽取              | 25        |

|                                          |           |
|------------------------------------------|-----------|
| 4.5.3 相似案例检索与规避风险建议生成 . . . . .          | 26        |
| 4.5.4 风险摘要生成与风险分析 . . . . .              | 27        |
| 4.6 客制化数字人生成技术 . . . . .                 | 28        |
| 4.6.1 换脸技术 (FaceFusion) . . . . .        | 29        |
| 4.6.2 图像脸部裁剪与增强技术 (CodeFormer) . . . . . | 29        |
| 4.6.3 音色克隆技术 (GPT-SoVits) . . . . .      | 30        |
| 4.6.4 视频生成技术 (V-Express) . . . . .       | 30        |
| 4.7 系统加速方案 . . . . .                     | 31        |
| 4.8 系统鲁棒性增强方案 . . . . .                  | 32        |
| 4.9 数据存储方案 . . . . .                     | 33        |
| <b>五、数据集构建方案 . . . . .</b>               | <b>33</b> |
| 5.1 案例数据来源 . . . . .                     | 33        |
| 5.1.1 原始数据收集 . . . . .                   | 33        |
| 5.1.2 案例数据样例 . . . . .                   | 34        |
| 5.1.3 数据筛选与整理 . . . . .                  | 34        |
| 5.2 数据生成方法 . . . . .                     | 34        |
| 5.2.1 Prompt 设计与实现 . . . . .             | 35        |
| 5.2.2 多轮对话引导 . . . . .                   | 38        |
| 5.2.3 多进程并行调用 . . . . .                  | 39        |
| 5.3 数据评估 . . . . .                       | 39        |
| 5.3.1 数据多样性 . . . . .                    | 39        |
| 5.3.2 任务相关度 . . . . .                    | 41        |
| 5.3.3 人类偏好评分 . . . . .                   | 41        |
| 5.4 数据筛选 . . . . .                       | 41        |
| <b>六、系统测试报告 . . . . .</b>                | <b>45</b> |
| 6.1 伪造音频检测 . . . . .                     | 45        |
| 6.2 合成图片检测 . . . . .                     | 45        |
| 6.3 合成人脸检测 . . . . .                     | 45        |
| 6.4 视频换脸检测 . . . . .                     | 46        |
| 6.5 文本风险检测 . . . . .                     | 46        |
| 6.6 吞吐率与延迟检测 . . . . .                   | 47        |
| 6.7 MMRASE 基准 . . . . .                  | 47        |

|                     |           |
|---------------------|-----------|
| <b>七、创新点</b>        | <b>49</b> |
| 7.1 系统设计            | 49        |
| 7.2 数据集构建           | 50        |
| 7.3 策略开发            | 50        |
| 7.4 大模型技术应用         | 51        |
| <b>八、实用性和应用前景</b>   | <b>52</b> |
| 8.1 应用前景            | 52        |
| 8.2 实用性             | 53        |
| <b>参考文献</b>         | <b>54</b> |
| <b>A 附录：项目文档</b>    | <b>57</b> |
| 1.1 项目代码框架          | 58        |
| 1.2 Quick Start     | 58        |
| 1.2.1 VideoPipeline | 59        |
| 1.2.2 ImagePipeline | 59        |
| 1.2.3 AudioPipeline | 59        |
| 1.2.4 DigitalHumans | 60        |
| 1.2.5 TextPipeline  | 61        |

## 一、项目背景和意义

随着人工智能 (AI) 技术的飞速发展及其在各行各业中的广泛应用, AI 已成为推动产业升级转型和经济高质量发展的关键驱动力。国务院发布的《新一代人工智能发展规划》明确了 AI 的战略地位, 并强调了加强 AI 安全保障的重要性。然而, 在 AI 技术快速普及的同时, 也伴随着一系列新的安全挑战, 尤其是在通信技术和数字技术快速普及的背景下, 诸如诈骗、谣言等风险内容不断增多。截至 2023 年 12 月底, 国家反诈中心累计向各地下发资金预警指令 940 万条, 公安机关累计见面劝阻 1389 万人次, 会同相关部门拦截诈骗电话 27.5 亿次, 短信 22.8 亿条, 处置涉诈域名网址 836.4 万个, 紧急拦截涉案资金 3288 亿元。这不仅对个人隐私构成威胁, 也对国家安全、经济发展和社会稳定构成了重大隐患。这些风险内容不仅包括传统的文字信息, 还涉及更加复杂的形式, 如利用深度学习技术生成的伪造人脸、声音和视频等。根据 2024 年 2 月 29 日奇安信集团对外发布的《2024 人工智能安全报告》, 2023 年基于 AI 的深度伪造欺诈暴增了 3000%, 基于 AI 的钓鱼邮件增长了 1000%; 目前已发现有多多个有国家背景的 APT 组织, 利用 AI 实施了十余起网络攻击事件……新型风险内容的出现使得传统的识别技术难以有效应对, 凸显出对于更高效、更精准的风险内容检测手段的需求。

鉴于此, 本项目旨在通过深入研究和利用先进的 AI 技术, 综合运用自然语言处理、计算机视觉、语音识别等多种技术手段, 以增强对多模态风险内容的分析和识别能力。我们将重点探索如何利用 AI 技术提高检测效率和准确率, 同时确保技术的安全性和可靠性, 为实现 AI 为推动网络安全事业发展赋能提供强有力的技术支持。这一项目的成功开发与应用将有助于提升国家整体的人工智能安全保障能力, 为构建更加安全、健康的网络环境添砖加瓦。

现有的内容检测方法在面对日益复杂、隐蔽、逼真、多样化的跨模态风险内容时显得力不从心, 显示出几点明显的局限性:

- 1) 现有的内容检测技术往往聚焦于单个任务, 仅能识别某种特定风险, 导致模型的训练样本往往较为有限, 对于非典型样本的泛化能力有限。
- 2) 现有的内容检测技术侧重于检测某种风险的有无, 缺乏对风险的具体类别进行细粒度分类的能力, 也无法准确定位到具体的风险点。
- 3) 现有的内容检测技术缺乏多模态能力, 无法融合风险内容中跨模态的内容进行检测和分析。
- 4) 现有的内容检测技术不基于显式的内容理解, 一方面无法对风险内容进行合理的分析, 另一方面也使得风险检测的可解释性不足。

从以往的经验看, 内容生成任务的难度一般要低于内容检测任务, 生成高质量内容要难于判定内容质量。换言之, 同一时期的内容检测技术一般能较好识别同时期的生成内容。因此, 既然利用 AI 技术制造风险内容是可行的, 那么利用现代 AI 技术构建一个

支持多模态、能对多种模态、多种形式、多种来源的内容中的可能存在的各种风险进行检测、细粒度分类、定位与分析的风险内容检测平台也一定是可行的。

本团队分析了现有风险检测方法的局限性，认为引入多模态的、通用的理解能力是解决这些局限性的关键。幸运的是，现下流行的大语言模型 (Large Language Model, LLM) 与多模态模型 (Multimodal Large Language Model, MLLM) 为我们提供了重要的基础组件。我们将基于大模型的通用理解能力和模态融合能力，结合多种先进的、不同层次的 deepfake 检测技术，综合使用检索增强生成技术 (Retrieval-Augmented Generation, RAG)[1]、上下文学习 (Incontext Learning, ICL)[2]、大模型推理与规划 (LLM reasoning and planning)、高效参数微调 (Parameter-Efficient Finetuning, PEFT) 等多种技术，构建一个强大的、可私有化部署的、多模态通用风险内容检测与分析平台。

除了风险内容检测平台的开发，我们也希望在数据集与测评基准方面上推进风险内容检测领域的发展。我们利用大量已脱敏的真实诈骗案例与对话数据，运用大模型与合成数据的相关技术，合成了一个约 300k 条样本的中文短信与对话细粒度风险分类数据集 (Fine-Grained Risk Classification Dataset for Chinese SMS and Conversational Dialogues, FGRC-SCD)，以弥补这一细分领域的空白。我们挑选了换脸检测、色情图片检测、伪声检测等其他模态、其他细分方向的风险检测任务的优秀数据集作为基础，并使用更现代的生成模型与更先进的 deepfake 技术生成少量数据 (Audio ChatTTS GPT-SoVITS dataset, ACG) 作为补充，与我们合成的 FGRC-SCD 数据集一起，构建了开源多模态多粒度风险内容检测基准 (Multimodal Multilevel Risk Analysis and Summary Evaluation Benchmark, MMRASE Benchmark)。我们将用 MMRASE 对我们的多模态风险内容检测平台进行测评，也期待 MMRASE 可以助推多模态风险检测领域的进一步发展。

本项目的实施预计将显著提升反诈骗技术的效能。根据基于诈骗短信预警测试和换脸识别测试的初步模型结果，我们的多模态风险检测平台的识别准确率可达到 92.71%。根据测试中成功识别内容的比例以及当前电信网络诈骗涉案金额与人数的估计，若本项目能够成功全面部署，该平台能有效识别并拦截至少 90% 的新型诈骗和深度伪造内容，预计可避免约 1844 万人次成为受骗者，拦截诈骗短信约 10.2 亿条，减少受骗金额约 20%。此外，本项目所构建的数据集与基准也可用于其他反电信诈骗的平台软件，推动电信网络诈骗治理工作，有效降低电信网络诈骗带来的风险与危害。

## 二、项目功能

本项目实现了与内容风险识别相关的多种功能，包括基础的风险识别与分类、风险摘要生成、风险点标注，以及风险分析、规避风险建议等。我们注意到，企业用户与个人用户的要求是不同的，前者对系统的效率、稳健性、吞吐量、支持的数据类型是否齐全等指标上有更高的要求，后者则希望系统能提供更加人性化的功能。因此，我们将我们的功能分为企业用户与个人用户两个部分介绍。




图1 企业用户、个人用户需求不同点




图2 企业用户、个人用户需求相同点

### 2.1 面向企业用户

企业用户的主要需求是快速、大批量地处理企业内部数据或其用户的数据，而这些数据可能是多种格式、多种模态的。因此，面向企业的功能重点在于将为多种输入进行统一的、细粒度的分类，并提供统一格式、高质量的风险摘要。同时，由于需要处理大量数据，要求在风险识别与分类的准确率、风险摘要质量达到要求的前提下，尽可能提高处理的效率、吞吐量，并扩大支持的数据类型。

2.1.1 多模态多粒度风险分类系统

本系统支持对多种模态的输入进行多粒度的风险分类，支持的输入类型包括：纯文本（包括短信、聊天记录、对话等）、视频、图像（包括富文本图片）、音频、PDF 文件、网页链接。我们从以下两个角度对内容风险进行了检测：内容伪造带来的可能次生风险与内容本身的风险。

|                  | 文本 | 视频 | 图像 | 音频 | 网页链接 | 文件 |
|------------------|----|----|----|----|------|----|
| 风险内容分析（诈骗、暴力、色情） | ✓  | ✓  | ✓  | ✓  | ✓    | ✓  |
| Deepfake 检测      |    | ✓  | ✓  |    |      |    |
|                  |    | ✓  | ✓  |    |      |    |
|                  |    | ✓  |    | ✓  |      |    |

表 1 输入与输出类型

内容伪造往往与诈骗、谣言等风险高度相关，如不法分子可能通过换脸、伪声等技术来伪装熟人、亲友并进行诈骗，或是用于编造谣言以博取流量等。因此，检测内容中是否存在伪造部分是风险检测的重要一环。我们主要关注以下三种形式的内容伪造：音频伪造（包括无参考的合成人声与有参考的伪造人声）、图像合成/换脸、视频合成/换脸，具体的检测方法将在技术方案中展开介绍。我们会将输入的各模态是否存在内容伪造这一信息作为风险摘要的一部分，并作为条件送入到后续的管线中，作为最终检测结果的重要参考。




图 3 deepfake 检测与内容风险检测

对内容本身风险的检测分为两个粒度，第一个粒度是判别内容是否存在暴力、色情、谣言、犯罪计划、诈骗等风险。由于经过指令微调的开源大语言模型一般已经完成了人类价值观对齐，故其对暴力、色情等有固定模式的风险在零样本设置下已有较好的识别能力。对于诈骗这类形式较为多样、内容较为灵活的风险内容，我们总结了常见的诈骗案例，结合已有的分类标准，将其分为了 10 种细分类型，以对诈骗风险进行更精确的归类。如果用户输入的内容在第一个粒度的检测中被认为存在涉诈风险，则进行第二个粒度的检测：判别内容具体涉及的细分诈骗类型。在这一任务上，直接使用零样本设置的大模型进行推理的效果较为一般。因此，我们将大模型作为数据生成器而非分类器，利用大模型的生成能力，将已有的大量诈骗案例描述作为种子数据，生成了大量用于细粒度风险分类的短信数据与对话数据，并利用这些合成数据，结合多种方法，有效提高了系统细粒度风险分类的准确率和效率。具体细节将在技术方案中报告。




图 4 三阶段分类管线图

2.1.2 风险摘要生成系统

本系统用于从多种模态的输入内容中抽取和总结出风险摘要，包括对原始内容的简单描述和对其中风险要素及其判断依据的概括。对于存在涉诈风险的内容，风险摘要中还会包括此类内容针对的目标人群。

由于需要处理多种模态的输入数据，且生成风险摘要需要建立在理解的基础上，我们将感知阶段与推理阶段解耦，引入了一个两阶段的方法：先通过视频理解模型、视觉语言大模型、OCR 模型、语音转文本模型等对输入内容进行感知，将各种模态的输入转为对应格式的文本描述，加上风险分类系统输出的多种标签一并送入大语言模型中进行推理，统一生成风险摘要。




图5 感知推理解耦管线图

## 2.2 面向个人用户

相比企业用户，面向个人用户的输出应该更加人性化，有更好的视觉效果与可读性。除了基础的风险分类与摘要生成功能外，我们还实现了风险点标注、风险分析与规避风险建议功能，方便用户更加直接地了解风险的具体来源、判别风险的具体依据、以及如何规避相似风险的方法。另外，我们注意到许多用户对于数字人诈骗这一新型的诈骗形式尚不了解，使得此类风险对用户的威胁程度较高。因此，我们在个人用户界面上提供了数字人实例和简单的客制化数字人体验界面，允许用户用自己的视频、照片、音频、文本来合成一个简单的数字人视频，并可用该合成视频测试我们的风险检测系统。

### 2.2.1 多模态风险点定位系统

本系统用于定位多种模态输入中的风险点，如从视频/图像中标注出伪造区域，从文本中标注出敏感的高风险词等。对于视频/图像中风险点的定位，我们主要关注对换脸区域的定位。对于文本中风险点的定位，我们通过将其转化为类似于“关键词抽取”的抽取任务来实现。具体细节见技术方案。



图6 文本风险定位




图 7 换脸风险定位

### 2.2.2 风险分析与规避风险建议系统

本系统用于对输入内容提供风险分析及简单的规避风险建议。我们利用大语言模型强大的理解能力和充沛的先验知识来完成这一任务。考虑到大语言模型的幻觉现象可能使其给出不够可靠的建议，我们使用了检索增强生成的范式（即 RAG），通过在生成前检索相关案例和有关的官方平台的规避风险建议，为模型的分析提供依据。在提高模型输出可靠性的同时，也方便用户了解相似案例，从而提高警惕。

### 2.2.3 数字人诈骗检测系统与客制化数字人体验

数字人作为目前生成式 AI 的集大成者，在当下具有重要的、广泛的应用场景。不同外形、不同功能的虚拟数字人赋能影视、传媒、游戏、金融、文旅等领域，为多个行业带来了革新与活力。但与此同时，这种技术的滥用也引发了社会问题，尤其是涉及到安全和隐私的问题。例如，一些不法分子利用高度仿真的数字人技术实施电信诈骗：他们通过模拟受害者亲友的声音和形象来获取信任，进而实施欺诈行为。这种新型犯罪手段不仅欺骗性强，而且追踪难度大，给执法机构带来了新的挑战。

本系统可用于对数字人视频进行检测，通过复用多模态风险分类系统中识别内容伪造的管线，对数字人视频中的音频、单帧图像和视频进行检测，识别其中的音频伪造、换脸、图像合成等痕迹。我们还提供了客制化数字人功能，允许用户以多种方式使用自己的素材制作数字人视频用于测试检测系统，包括使用单张人像图片、示例音频（用于

提供音色)和目标文本(用于控制视频内容)来合成说话人视频,或是使用单张图片与示例视频通过换脸技术合成视频。

同时,作为矛与盾的关系,伪造检测技术与生产技术总是在不断的发展与对抗中进步。检测系统的应用对于促进生成技术的更新迭代、推进数字人的逼真化发展具有重要的正向作用。

2.2.4 Android 短信风险实时判断 App

这是一个简易的、基于 Android 系统的短信风险检测 App。平时只需要保持该 App 在后台运行。当用户接受到短信时,该 App 能将短信实时发往服务器中的文本风险检测服务端进行风险分析,并将结果返回用户端。用户会接到弹窗提醒短信风险,点击弹窗后能看到具体的风险分析和防范建议。该 App 通过 Android Studio 的广播机制实时获取手机接收到的短信,并通过 FastAPI 实现数据在 java 程序(客户端)和 Python 程序(服务端)间的传递。




图 8 短信风险实时判断

### 三、项目功能展示




图 9 视频风险检测



图 10 图像风险检测



图 11 声音风险检测



图 12 短信风险检测




图 13 网页风险检测



图 14 PDF 风险检测



图 15 企业端页面

## 四、技术方案

### 4.1 项目总体架构




图 16 总体框架

本项目主要基于 FastAPI 与 Gradio 构建，采用前后端分离架构。我们通过 Gradio 构建简单的用户界面来支持用户上传多种格式的数据，通过服务分发层将服务转发到对应的子服务进行处理。在模型层，我们采用了感知与推理解耦的框架，将多种模态的输入通过多模态感知层（包括视觉文本大模型、OCR 模型、语音转文本模型）统一转换为文本描述，再将统一的文本描述送入以 RAG 为中心的检索与推理层完成相似案例检索、风险摘要生成、风险分析、规避风险建议等任务。此外，模型层还集成了一些高效的 deepfake 检测小模型，以对内容伪造风险进行检测。

#### 4.1.1 FastAPI

FastAPI 是一个用于构建 API 的现代、快速、高性能的 web 框架，我们使用 FastAPI 将子功能逻辑和可能被多个功能共用的模型封装为 RESTful API，相比直接使用模型具有以下优势：

- 1) 对各子功能进行解耦，支持跨 python 环境和跨语言交互。由于各子模块、模型需要的 python 环境不一致，存在部分库、CUDA 版本无法相互兼容的情况，无法将所有模型运行在一个统一的环境下。而我们使用 FastAPI 将子模块与模型包装为服务，以支持跨环境交互。这一设计也允许我们在 java 和 python 之间进行交互，极大减小了我们开发安卓端 app 的难度。
- 2) 支持模型的提前加载，与 vllm 等现代推理引擎兼容。若每次使用模型时都需要将模型导入 gpu 将耗费大量时间，而使用 FastAPI 框架将模型包装成 api 端口能将模型提前导入 gpu；需要使用模型时，只需向对应 api 端口提出请求，服务端将调用已载入 gpu 的模型，从而快速得到模型输出。
- 3) 增强了系统可拓展性，更换子模块和模型时无需对其他部分进行任何修改。增加新功能、新模型时只需开发、部署新的子服务，而无需对原有系统进行较大改动，使系统持续迭代、进化的难度较小。

#### 4.1.2 Gradio

Gradio 是一个开源的 Python 库，用于快速构建 demo 和 web 应用程序来演示深度学习模型，将 AI 算法转换成可视化界面。其具有以下优点：

- 1) 方便多模态数据的上传和使用。Gradio 内置 Text、Video、Image、Audio 等函数，支持文字、视频、图像、声音等模态的一键上传和使用。
- 2) 易于构建。Gradio 简单、方便，相较于 vue、react 等前端框架易于上手，使我们能在短时间内构建出一个可用于展示功能的 web demo。

## 4.2 视频检测




图 17 视频管线图

对于输入的视频，我们从以下几个方面检测视频是否存在风险：

- 1) 检测视频内容是否存在风险。
- 2) 检测视频中的人脸是否被替换。
- 3) 检测视频中是否存在色情内容。
- 4) 检测视频的音频信号是否是伪造的。
- 5) 检测视频的音频信号的内容是否存在风险。

我们可以通过以下方法完成检测：

- 1) 将视频均等的抽出十帧，将这十张图片送入视觉-文本大模型 LLaVa-NeXT，获取每张图片的风险内容。再将这些抽帧图片的风险内容送入大语言模型 llama-chinese，总结出整个视频的风险内容。
- 2) 将视频送入 VideoFACT 模型，检测视频中人脸是否被替换。
- 3) 将抽帧所得的图片送入 opennsfw2 模型检测视频是否存在色情内容。
- 4) 抽取视频的音频信号送入 DeepFake-Audio-Detection-MFCC 模型判断音频信号是否存在伪造，和 whisper-large-v3 模型 [3] 判断音频内容是否存在风险。




图 18 抽帧示意图

#### 4.2.1 视频内容风险检测

对于视频风险检测，我们尝试直接使用视频理解大模型来检测视频内容中的风险，但现有的开源视频理解模型的中文能力较为有限，指令跟随能力与先进的大语言模型相比仍有差距。因此，我们将视频进行抽帧，使用开源的视觉-文本大模型 LLaVa-NeXT 来进行视频理解。LLaVa-NeXT 是一个建立在开源大语言模型 llama3 基础上的多模态大模型 [4]，可以用于图像问答等多模态任务。我们将抽帧后的图片序列通过 LLaVa-NeXT 进行初步风险分析和内容描述，再将内容描述合并后输入文本模态检测管线进行进一步的风险分析。

#### 4.2.2 视频内容伪造检测




图 19 VideoFACT

对于视频伪造检测，我们主要借鉴了开源项目 VideoFACT。这是一个使用注意力 (attention)、现场上下文 (scene context) 和取证追踪 (forensic traces) 来检测视频伪造的模型 [5]。其通过上下文嵌入 (context embeddings) 以控制取证痕迹的变化，且通过深度自

注意力机制 (deep self-attention mechanism) 来估计取证嵌入的质量和相对重要性。此外, 研究人员还专门开发了多个新的视频伪造数据集, 既包括了标准视频操作 (如拼接) 又有高级操作 (如基于 AI 的修复) 以确保模型具有最佳的视频伪造检测和定位性能。在测试的过程中, 我们发现该模型对“视频中人脸是否替换”这一任务的判断准确率不高。故在原权重的基础上使用 DFMNIST+ 数据集微调了部分层的参数, 使其对人脸伪造检测达到较高的准确率。DFMNIST+ 数据集包含了 10000 个伪造视频和 10000 个真实视频。其中, 10000 个伪造视频被分为 10 个动作, 包括眨眼、点头、微笑等动作; 每个动作有 1000 个伪造视频。我们将这些视频以 8:1:1 划分成训练集、测试集、验证集。真实视频按 14:3:3 划分。将微调后的模型在测试集上测试, 模型的准确率达到 85.11%。

### 4.3 图像检测

对于图像模态, 我们可以从以下几个角度判别图片是否具有风险

- 1) 图像本身是否是伪造的 (包括背景、人脸等)
- 2) 图像中的人脸是否经过 AI 换脸
- 3) 图像本身是否具有裸露、色情的部分
- 4) 对于文本图像 (Text Image), 这些文本是否本身含有风险信息
- 5) 图像本身的内容是否存在风险

#### 4.3.1 伪造图像检测

传统伪造图像检测模型通常只能检测训练过程中见过的特定类型的伪造图像, 泛化能力较差。针对这一点, 我们借鉴了开源模型 UniversalFakeDetect[6] 来帮助我们进行伪造图像的检测, UniversalFakeDetect 通过使用未经专门训练的特征空间, 实现了对多种类型的伪造图像的检测, 如深度伪造 (deepfake)、样式转化 (style transfer)、传统图像篡改等。该模型的主要检测类型包括:

- 1) 生成对抗网络 (Generative Adversarial Networks, GAN) 生成的伪造图像: 如 ProGAN、CycleGAN 和 BigGAN 等生成的图像。
- 2) 扩散模型 (Diffusion Model) 生成的伪造图像: 如 Latent Diffusion Model (LDM) 和 Guided Diffusion 等生成的图像。
- 3) 自回归模型 (Autoregressive Model) 生成的伪造图像: 如 DALL-E 等生成的图像

在诈骗场合中, 伪造人脸图像的手段非常常见, 如身份盗窃、金融欺诈等。针对这一现象, 我们将 UniversalFakeDetect 在 DFFD 数据集上进行微调, 使其更专注于识别人脸是否是合成的。DFFD 数据集包含由不同方法生成的伪造人脸, 如 FaceSwap、DeepFakes、Face2Face、NeuralTextures 等, 其多样性使模型能够检测不同类型的伪造人脸。通过在 DFFD 数据集上的微调, 最终模型在测试集上的准确率能达到 96.75%, 在分类任务中具

有较高的精度。

#### 4.3.2 换脸图像检测

在诈骗场合中，一般通过诈骗短信和视频通话作为诈骗方式，很少采取单张图像的换脸诈骗，因此在图像模态的换脸检测中，我们主要针对的是一组视频抽帧的图像，通过时序线索 (Temporal Clue) 来对图像进行分析。

时序线索指的是从视频抽帧的图像中提取到的时间相关信息，如通过比较连续帧来识别异常行为等。

对此，我们借鉴了开源项目 Combining EfficientNet and Vision Transformers for Video Deepfake Detection[7]。该模型将 EfficientNet 和 Vision Transformers(ViT) 提取的特征进行有效结合，充分利用两种模型的优势，提出卷积交叉 ViTs(the Convolutional Cross ViT)，以捕获局部和全局细节。除此之外，还通过时序数据增强等方式使图像的时序线索更加明显的被模型识别出来，有利于模型准确性的提高。

#### 4.3.3 色情图像检测

许多钓鱼网站会利用色情内容作为诱饵，吸引用户点击链接或下载文件，进而获取用户信息等。诈骗分子也可能在交友平台或成人内容网站上利用色情内容进行诈骗，因此色情图像检测可以作为识别风险的重要依据之一。

传统色情图像检测是通过计算暴露皮肤的百分比来判断的，如 python 中的 nonude 模块，当暴露皮肤的百分比超过 15%，而且识别结果只有“真”“假”两种情况，准确率较低。相比之下，我们参考了开源模型 Opennsfw2，该项目采用深度学习技术，通过对图像打分的方式评判图像是否具有色情内容。

#### 4.3.4 文本图像检测

由于许多诈骗活动是通过聊天进行的，因此聊天记录也可能涉及一些潜在的风险。对于这类文本和图像内容，需要特别关注其可能隐藏的安全隐患。针对这一类文本图像，我们采用光学字符识别 (Optical Character Recognition,OCR) 提取文本信息，再输送到文本通道进行风险识别与判断。

我们选取 CnOcr 模型来实现这一任务。目前许多 ocr 模型是为多语言设计识别的，在中文字符上的识别准确率没有那么多高；而 CnOcr 更专注于中文字符，使其在处理中文文本图像时具有更高的准确性，并能处理不同类型的中文文本，如印刷体，手写体等。除此之外，CnOcr 还集成了一些高效的后续处理算法，如字符拼接，错字纠正等，使得整体识别更加高效准确。




图 20 OCR 提取文本信息

## 4.4 音频检测

对于音频模态，我们主要进行两个方面的检测工作：

- 1) 音频的内容是否具有诈骗、色情、暴力等内容
- 2) 音频本身是否为生成的伪造音频

### 4.4.1 音频风险检测

对于音频风险检测，我们通过语音转文字模型 `whisper-large-v3` [3] 将语音转换为文字，再输出到文本通道进行内容方面的风险识别与判断。该模型是一种用于自动语音识别 (Automatic Speech Recognition, ASR) 和语音翻译的预训练模型。Whisper 模型基于 68 万小时的标记数据进行训练，表现出强大的泛化能力，可适用于许多数据集和领域，而无需进行微调。这为我们的工作提供了极大的便利。

### 4.4.2 音频伪造检测

对于音频伪造检测，我们参考了开源项目 `DeepFake-Audio-Detection-MFCC`，该模型使用从音频文件中提取的 MFCC（梅尔频率倒谱系数）特征和支持向量机（Support Vector Machine, SVM）分类器来区分真实音频和深度伪造音频。但原有的模型权重是在较老的数据集上训练得到的，对于目前语音生成大模型（eg. ChatTTS）所伪造的音频无

法进行精确地识别。因此，我们利用 Codecfake[8] 数据集中的部分数据构建了一个新的音频伪造识别数据集对原有项目进行重新训练，旨在提高该模型对于伪造音频，特别是利用目前主流大模型生成的音频的鉴别能力，尤其是针对数字人合成中常用的 ChatTTS 以及 GPT-SoVITS 生成的伪造音频进行有效检测。ChatTTS 和 GPT-SoVITS 都是在文本转语音（TTS）领域的重要开源项目。它们各自有不同的优势。ChatTTS 专门为对话任务设计，适用于 LLM 助手对话任务、对话音频和视频介绍等。支持细粒度控制，可以预测和控制细粒度的韵律特征，如笑声、停顿和语气词。GPT-SoVITS 模型采用直接偏好优化 (Direct Preference Optimization, DPO)，这是一种简单的无强化学习算法，用于从偏好中训练语言模型。这使得 GPT-SoVITS 在少样本中文声音克隆方面表现出色，能够生成具有人类语言细微差别、情感和独特性的声音。数据集构建方式如下：

我们首先采取 Codecfake 数据集中的 4391 条中文语音数据作为真实音频数据，通过 faster-whisper-large-v3 将其转化为文本条目，再通过 ChatTTS 大模型以及 GPT-SoVITS 模型根据提取的文本进行语音生成，形成 4555 条由 ChatTTS 生成的伪造音频数据以及 2645 条由 GPT-SoVITS 生成的伪造音频数据。接着，我们将 4391 条真实音频数据混合 7200 条伪造音频数据作为训练数据对 DeepFake-Audio-Detection-MFCC 进行训练。最后，我们将训练好的模型在由 4554 条通过 ChatTTS 生成的伪造音频、376 条通过 GPT-SoVITS 生成的伪造音频数据以及 4388 条 Codecfake 数据集中真实音频数据构成的测试集上进行测试，得到正确率为 91.23%。

## 4.5 文本检测

### 4.5.1 两层次文本风险分类

我们对文本进行了两个层次的风险分类：先检测文本是否包含暴力、色情、谣言、煽动、诈骗等风险；如果文本含有涉诈风险，则再对文本可能隐含的诈骗类型进行进一步的细分类。

对于第一个层次的风险分类，由于开源大模型（均指指令微调版本，下同）出于安全考虑，都会在 SFT 阶段和 RLHF 阶段进行人类价值观对齐，它们对于暴力、色情等与人类基本价值观相悖的风险内容有非常敏锐的识别能力。我们发现直接使用大语言模型（如 llama3-chat-chinese-8B, qwen2-instruct-8B）在零样本设置下使用简单的提示词进行推理就可以有非常稳定的检测效果。因此，我们没有为这一功能对大语言模型进行微调或是引入复杂的推理方法，只需在大模型完成其他分析性任务的同时输出风险类别即可。

对于第二个层次的风险分类，即对内容涉及的细分风险类别进行识别，我们发现在零样本设置下直接使用大模型进行分类的准确率有限。因此，我们尝试了基于大模型与不基于大模型的四种方案来提高分类的准确率。我们将使用我们合成的 FGRC-SCD 数据集微调和测试我们的模型。数据集构建的具体细节将在第四章介绍。

## 方法 1: 使用高效参数微调方法对大模型进行指令微调

考虑到风险分类等任务对模型的复杂推理能力没有太高要求，且部分用户可能有私有化部署需求，我们使用了 8B 级别的轻量级大模型。尽管如此，对轻量级大模型进行全量微调依然有很高的显存需求和算力需求。另一方面，由于 FGRC-SCD 中的数据量有限且范围较窄，对大模型进行全量微调可能会造成原有通用知识的遗忘，使通用模型退化为特定任务上的分类器。如果每一类任务都使用一个独立的微调后的大模型进行推理，系统运行的基础显存需求会过高，从而压缩了 KVCache 空间，可能使系统的响应速度下降。

综合以上原因，我们选择使用 LoRA(Low Rank Adaptation) [9] 对大模型进行微调。LoRA 通过低秩矩阵的乘积来表达参数更新量，实现了参数更新量的重参数化，从而大大减少了微调时需要训练的参数，显著降低了显存和计算量。同时，LoRA 作为适配器，具有可插拔的特性。我们可以在多个任务上分别训练 LoRA，并在需要处理相关任务时切换特定任务的 LoRA 进行推理即可，而无需存储多份大模型权重。对于固定任务的场景，我们可以将 LoRA 权重与原权重融合，从而进一步降低推理开销。




图 21 LoRA 微调

我们使用了 rank=64, alpha=32 的 LoRA 设置，使用 AdamW 优化器在 FGRC-SCD 数据集上对 llama3-chat-Chinese-8B 微调了一个 epoch，最终测得模型在短信测试集上分类准确率为 86.92%，在对话测试集上分类准确率为 51.02%。

## 方法 2: 使用 embedding 模型将输入内容向量化，再训练一个分类头进行分类

在实现基于 RAG 方法的其他功能的过程中，我们发现 embedding 模型往往会召回类别一致的案例。可以自然地想到，既然 embedding 模型可以召回类别一致的案例，直接使用 embedding 模型进行分类具有可行性。我们在 embedding 模型后增加了一个 MLP 作为分类头，冻结 embedding 模型，对 MLP 进行在 FGRC-SCD 训练集上、使用 AdamW 优化器训练了 100 个 epoch，最终在短信、对话测试集上准确率为 61.87%、29.70%。

## 方法 3: 直接微调预训练的 BERT 模型进行分类

我们猜测方法 3 效果不佳的原因是可训练的参数过少，因此尽管能在训练集上

达到较高准确率，却无法很好地泛化到测试集。由于 embedding 模型较大，直接微调 embedding 模型的成本较高，我们选择回归文本分类的传统范式，对经过中文预训练的中等大小的 BERT 类模型进行微调作为分类器。我们选择了 ernie-3.0-xbase-zh 作为基础模型 [10]，在 FGRC-SCD 训练集上使用 AdamW 优化器训练了 1 个 epoch，最终在短信测试集准确率为 94.9%，对话测试集上准确率为 88.0%。

表 2 短信与对话诈骗风险分类各方案准确率

| dataset/method   | LLM + zero-shot | LLM + LoRA | embedding model + classifier | BERT + finetune |
|------------------|-----------------|------------|------------------------------|-----------------|
| FGRC-SCD(sms)    | 49.15%          | 86.92%     | 61.87%                       | 94.9%           |
| FGRC-SCD(dialog) | 41.75%          | 51.02%     | 29.70%                       | 88.0%           |

4.5.2 文本风险点抽取

文本风险点抽取是一个典型的抽取任务，故我们借鉴了关键词抽取的常用方法，如 KeyBERT [11] 和 KeyLLM。KeyBERT 是一种基于 BERT (Bidirectional Encoder Representations from Transformers) 模型的关键字提取方法，其核心原理是利用 BERT 生成上下文语境下的词语级嵌入，与语句级嵌入比较相似度，从而识别关键词。KeyLLM 则利用预训练的大语言模型，直接通过指令将抽取任务转换为生成任务处理。尽管 KeyBERT 在关键词抽取任务上效率较高，但其不基于显式的内容理解，故无法在不经微调的前提下迁移到风险点抽取任务。而 KeyLLM 可通过修改提示词调整对特定内容的关注程度，具有更高的灵活性与可拓展性。

我们使用如下指令进行风险点抽取：

```
prompt = (  
    f"从以下文本中提取风险点"  
    "风险点应以逗号分隔"  
    "必须从原文中提取"  
)
```

为了进一步增强模型的指令跟随程度，我们采用 few-shot 设置，对 prompt 进行了针对性的设计，通过多轮对话引导模型完成任务。

```
text1 = "您好，欢迎加入百花齐放群，这里有很多赚钱的机会。请点击链接下载STQ软件，按照提示购买  
    春、夏、秋、东即可获得收益。记得先充值哦，这样才能开始赚钱。"  
text2 = "您好，我是金源贷款的客服，请问您是否有贷款需求？如果有，可以加我的QQ（QQ号：  
    123456789）详细了解。我们提供快速便捷的贷款服务，您只需下载我们的APP并填写相关信息即  
    可。"  
text3 = "您好，请问您是否开通了京东金条？为了您的账户安全，我们建议您尽快注销该服务。请您下载  
    云视讯APP，并在APP内按照指示操作，将您建设银行账户中的资金转至我们提供的建行账户，以完
```

成注销流程。”

```
response = client.chat.completions.create(
    model="llama3",
    messages=[
        {"role": "system", "content": prompt},
        {"role": "user", "content": text1},
        {"role": "assistant", "content": "点击链接下载,先充值"},
        {"role": "user", "content": text2},
        {"role": "assistant", "content": "下载我们的APP,填写相关信息"},
        {"role": "user", "content": text3},
        {"role": "assistant", "content": "下载云视讯APP,资金转至我们提供的建行账户"},
        {"role": "user", "content": content}
    ],
    stream=False
)
```

为了确保风险点在原文中，我们还对模型返回结果进行了简单的后处理，确保结果的正确返回。

#### 4.5.3 相似案例检索与规避风险建议生成

部分类型的风险（如诈骗、谣言）具有快速迭代的特点，其类型与形式可能随时间快速变化。为了使系统能以较低成本获得具有较好的时效性，我们希望通过更新风险案例库而非重新微调模型的方式来实现系统的持续进化能力。

在文本模态推理阶段，我们使用了检索增强生成 (RAG) 的经典框架。先将风险案例库按案例进行自然分块，通过 `embedding` 模型 (如 `bge-large-zh-v1.5`) 压缩为嵌入向量，并根据数据规模建立单层或多层索引。将多个模态的输入内容通过多模态感知层转换为文本后，使用 `embedding` 模型将输入压缩为向量用于检索。当风险案例数据库数据量较小时，我们以输入文本向量与案例向量的余弦值为距离度量，直接召回 `top-k` 的风险案例。当风险案例数据量较大时，直接进行线性扫描的效率较低。我们先使用近似最近邻 (ANN) 算法召回较多的近似最相似案例，再使用 `Reranker` 模型 (如 `bge-reranker-large`) 对召回的案例进行精排，最后将重排后相关性最高的 `k` 个案例作为最终的相似案例，并加入到大语言模型的输入中来辅助规避风险建议的生成。

表 3 风险摘要与风险分析质量测评

| dataset/method   | LLM+few-shot(n=1) | LLM+LoRA+few-shot(n=1) |
|------------------|-------------------|------------------------|
| FGRC-SCD(sms)    | 1.10              | <b>1.66</b>            |
| FGRC-SCD(dialog) | 0.82              | <b>1.92</b>            |




图 22 检索增强生成

#### 4.5.4 风险摘要生成与风险分析

我们先将用户文本输入、用户其他模态的输入经多模态感知层转换的文本描述、各 deepfake 检测模型对输入内容各模态的伪造/合成判断结果、文本粗粒度风险分类结果、诈骗风险细分类结果、检索到的相似案例按一定格式拼接，再使用大模型对上述内容进行统一整合与分析，给出最终的风险分析结论和风险摘要。为了使模型更好遵循指令，我们仍然使用 few-shot 设置，通过多轮对话引导的方式控制模型生成内容的风格，提高风险摘要质量。

我们构建的 FGRC-SCD 数据集不包含参考摘要，无法使用传统的基于真值的摘要质量测评方法；而人工测评的方法则效率明显过低。因此，我们使用基于大模型的自动测评方法，使用经过大量人类反馈预训练的 reward model 对大模型在 FGRC 上生成的风险摘要和风险分析的质量进行测评。我们使用大模型 llama3-chat-chinese-8B，在 few-shot(n=1) 的设置下进行风险摘要生成与风险分析，其生成文本的质量在 InternLM2-7B-Reward 上测评的平均值分别为 1.10/0.82（短信/对话）。

我们尝试将诈骗风险细粒度分类任务上训练的 LoRA 直接用于风险摘要生成和风险分析任务，生成文本的质量在 InternLM2-7B-Reward 上测评的平均值提升到 1.66/1.92（短信/对话），可见使用指令微调的方式对模型进行训练可以泛化到相同领域的不同任务上。

同时，为了增强系统的自我进化能力，以应对越来越复杂、隐蔽的多模态风险内容，我们会在获得用户许可的前提下将用户的文本输入、非文本输入经多模态感知层转换的文本描述及其对应模型输出的风险摘要脱敏后进行存储，以构建风险案例数据库。该案例数据库可用于 RAG 以增强模型输出质量，并通过人工添加新型案例来提高系统时效性，也可经筛选和清洗后构建为数据集，用于微调模型，进一步提高模型在生成风险摘要和风险分析这一任务上的能力。

4.6 客制化数字人生成技术

客制化数字人生成技术主要由两大技术通路组成：第一部分为视频换脸技术，个人用户可利用特定的头像图片对视频中的人脸进行高质量替换，体验 AI 视频换脸，该部分功能主要通过 Facefusion 模型实现；第二部分为通过输入的含有目标人脸的图片、目标人物的音频，以及想要生成的目标人物的讲话内容文本，生成目标人物讲述按照指定音频的音色讲述指定文本的视频，让个人用户进一步体验数字人生成的过程与效果。该部分主要通过 CodeFormer、GPT-SoVits 以及 V-Express 三个模型联合实现。下面我们将分别进行更加详尽的介绍：




图 23 数字人工具包结构图

#### 4.6.1 换脸技术 (FaceFusion)

FaceFusion(Next generation face swapper and enhancer) 是一个综合换脸、人脸增强等功能的开源项目，是一款基于深度学习和人脸识别的合成软件。通过训练大量的面部数据，它能够精确地定位人脸的关键点，从而实现人脸替换合成。相比过去的换脸模型软件，FaceFusion 对面部识别拥有更高的准确性，合成效果具有明显提升。它不仅能够对静态图片进行人脸替换，还能够对动态的视频进行人脸替换。其软件功能细则包括换脸功能组合、换脸模型选择、遮罩相关选项（用于处理原图像含有面部遮罩的情况）等，用户可以灵活选择换脸的相关参数，从而满足需要。在实际应用中，我们主要利用 FaceFusion 参与客制化功能实现，使用其进行人脸替换：根据用户给定的替换目标模板图片和替换脸模板图片，使用 FaceFusion 的模型完成替换操作，返回给用户。




图 24 FaceFusion 模型效果

#### 4.6.2 图像脸部裁剪与增强技术 (CodeFormer)

CodeFormer 是由南洋理工大学-商汤科技联合研究中心 S-Lab 在 NeurIPS 2022 上提出的一种基于 VQGAN+Transformer 的人脸复原模型。该方法基于预训练 VQGAN 离散码本空间，改变复原任务的固有范式，将人脸复原任务转成 Code 序列的预测任务，大幅度降低了复原任务映射的不确定性，同时 VQGAN 的码本先验也为复原任务提供了丰富的人脸细节。最后，通过 Transformer 全局建模，进一步增加了模型对严重退化的

鲁棒性，使得复原的人脸更加真实 [12]。在实际应用中，我们主要利用该模型完成两大任务：一是先对个人用户输入的图片进行人脸的裁剪提取，再对提取出的人脸进行修复增强，获得清晰真实的人脸图片；二是对最终生成的数字人视频进行进一步的增强，提高视频的清晰度。



图 25 CodeFormer 模型效果

#### 4.6.3 音色克隆技术 (GPT-SoVits)

GPT-SoVITS 是一个开源的声音克隆项目，该声音合成工具结合了 GPT(Generative Pre-trained Transformer) 模型和 SoVITS(Speech-to-Video Voice Transformation System) 变声器技术，仅需通过少量的样本数据实现高质量的语音克隆和文本到语音转换 (TTS)。该工具特别适用于需要快速生成特定人声的场景，可以帮助用户在没有或只有少量目标说话人语音样本的情况下，训练出能够模仿出该说话人声音 (包括感情、音色、语速) 的模型。在实际应用中，我们利用 GPT-SoVITS 模型实现通过用户输入的目标人物音频以及想要伪造的语音文本生成诈骗音频的功能。

#### 4.6.4 视频生成技术 (V-Express)

V-Express 是由南京大学和腾讯 AI 实验室共同开发的一项可以把单张照片变成视频的技术，并且它能够根据不同的信号，如声音、姿势、图像参考等来控制视频内容 [13]。它确保了弱信号也能有效地影响最终生成的视频，让视频生成更加逼真和多样化。V-Express 在肖像视频生成领域有几个显著的特点，使其与其他方法有所不同，这也是我们最终选择采用该模型的原因所在。

- 1) 渐近式控制信号平衡。许多现有方法直接利用控制信号生成视频，较弱的控制信号 (如音频) 往往会被较强的信号 (如姿势和图像) 掩盖，导致视频生成时弱信号的影响力较弱。而 V-Epxress 模型通过一系列渐进丢弃操作，逐步增强弱信号的影响力，确保弱信号能够有效控制视频内容。这种渐进式的方法使得不同强度的信号能够更好地平衡和融合。
- 2) 多种信号的融合。其他方法通常只能处理少量类型的控制信号，且在处理多个信号

时效果不佳；而 V-Express 模型能够同时处理多种类型的控制信号（如文本、音频、图像参考、姿势、深度图等），并且通过渐进式训练方法确保每种信号都能有效地发挥作用。

- 3) 其他方法大多侧重于图像和姿势等较强信号的控制，音频控制效果较差。而 V-Express 模型特别关注音频信号的控制，通过渐进丢弃的方法增强音频信号的影响力，使得音频信号在视频生成中能够起到重要作用，生成的肖像视频能够更好地与音频同步。

在实际应用中，我们利用 V-Express 模型，以经过 CodeFormer 模型处理的人脸图像和由 GPT-SoVits 模型生成的伪造音频作为输入，生成一段目标人物的讲话视频。实验结果表明，该方案生成的数字人视频与目标人物的真实讲话视频相似度极高，具有潜在的误导性。

## 4.7 系统加速方案

延迟是系统性能的重要指标，也是用户体验的重要因素。目前常用的延迟指标是首 token 延迟 (Time To First Token, TTFT)，我们采用了多种优化方法来降低 TTFT。

首先，我们对延迟的关键路径进行了分析，确定了延迟的主要来源为文件 IO、ffmpeg 视频处理和大模型推理。文件 IO 的延迟主要来源于视频抽帧后存在大量图像文件需要经过文件系统在不同模块间交互。我们尽可能通过直接传递图像对象来避免对图像的 IO；对于无法避免的 IO 使用多进程来减小多次 IO 带来的延迟。ffmpeg 视频处理可使用 GPU 进行加速，加快抽帧过程。

在模型推理加速方面，我们选择使用 vllm 推理引擎，以集成多种推理优化方法：

- 1) **PagedAttention**：vllm 的核心算法是 PagedAttention 算法 [14]，通过类似于操作系统中虚拟内存的管理方式来对 KVCache 进行页式管理，显著减少因批次文本长度不一致导致的显存碎片浪费，实现了显存的高效利用，从而大大提高系统的吞吐并降低延迟。
- 2) **Prefix-Caching**：vllm 还支持 Prefix-Caching，即对大量输入中相同的前缀进行缓存，避免了重复计算。考虑到我们的系统中固定的提示词和示例在整体输入中的占比较高，prefix-caching 能带来相当可观的性能优化。
- 3) **模型复用与批合并**：通过使用 vllm 框架将大语言模型和视觉文本大模型包装为 OpenAI 式的 API 服务，既便于多个模块使用同一模型，避免重复加载模型，又能利用框架特性实现自动的服务批合并，实现对多个任务的并行推理。

对于 vllm 未支持的模型，我们使用特定的加速库或 onnx 进行推理加速。最后，我们将推理结果进行流式返回，进一步降低了 TTFT，提高了用户体验。




图 26 PagedAttention 算法

## 4.8 系统鲁棒性增强方案

由于系统集成了多个子服务、子模块和模型，且不同组件之间可能需要相互通信，这使得系统复杂度较高，出错的概率大大提高。另一方面，系统中的部分模型仅在研究性质的数据集或是较小的数据集上进行训练，对于分布外样本可能给出错误的判断结果，这可能使得系统最终的输出与期待输出有较大偏差。

提高系统鲁棒性系统的首要任务是让系统能在部分组件崩溃的情况下仍可正常运行，并通过自动重启服务、重新加载模型等方式尝试恢复。为此我们采取了如下设施：

- 1) **分离式服务**：采用分离式架构设计子服务，防止单个子服务崩溃导致系统崩溃。
- 2) **异常输入处理**：利用异常处理机制和显式处理空值、无效值等方式避免代码因非法输入而崩溃。
- 3) **指数延迟重启**：使用守护进程监听各服务状态，采用指数延迟重启策略尝试重启崩溃的子服务，并及时报告在最大延迟下指定次数内无法重启的服务。

另一方面，系统应该能在部分模型输出错误结果时仍能给出相对合理的输出。我们主要使用以下两个方案来实现该目标：

- 1) **模型集成**：对于视频换脸检测等难度较高的任务，我们使用关注域（时域、空域、频域）不同的多个模型同时进行检测并将输出根据需求按不同方式集成为最终输出，以尽可能减小单个模型错误对系统输出带来的影响，增加系统容错。
- 2) **缺失示例策略**：在统一模态推理阶段，将部分示例输入中的部分项随机替换为缺失值或错值，如将示例输入中的图片文本描述替换为无，或将示例输入中的音频伪造检测结果替换为未检测或相反值，以让大模型通过上下文学习对其他模型的错误输出具有一定容忍能力与适应能力。更进一步地，在系统上收集较多多模态训练数据后，可以将该策略引入到训练阶段，通过在训练数据中混入少量经缺失处理的样本来进一步提高系统鲁棒性。

4.9 数据存储方案

考虑到企业端需要处理大批量的数据，而且这些数据同时又可以用于 RAG 来增强模型输出质量，因此我们采用数据库进行存储。由于图像、视频等大文件不适合存进数据库，我们只在数据库中存储文本模态形式的数据。

在数据库选择方面，我们选取 MongoDB 作为我们的数据库管理系统，一方面，对于不同模态的输入，最终送到文本模块的内容具有不同的结构。MongoDB 是 NoSQL 数据库，存储类型灵活，无需定义模式即可存储数据，且可扩展性强，适合存储异构数据。另一方面，考虑到在企业端方面，我们需要不断处理海量的数据；并且对于数据库里的数据，我们需要用 RAG 来增强模型输出质量，因此需要不断的进行查询。而 MongoDB 支持在数据上进行高效的查询和索引，支持处理大规模数据和高效并发访问。

```
"input": {
  "来源": "文本",
  "文本内容": "您好，欢迎加入百花齐放群，这里有很多赚钱的机会。请点击链接下载STQ软件，按照提示购买春、夏、秋、东即可获得收益。记得先充值哦，这样才能开始赚钱。",
},
"output": {
  "是否存在风险内容": "是",
  "风险摘要": "该文本内容中存在诈骗风险，通过提供虚假的赚钱机会，诱导用户下载并购买软件，并要求充值以开始赚钱。",
  "识别的风险类型": "诈骗",
  "风险内容分析": "诈骗：文本中通过提供虚假的赚钱机会，诱导用户下载并购买软件，并要求充值以开始赚钱，这种行为属于涉及财务信息的不合理要求，试图诱导用户提供个人信息或进行转账。",
  "防范建议": "诈骗：不随意下载或购买未经核实的软件，不轻信未经证实的赚钱机会，保持警惕。",
  "细分诈骗类型": "虚假网络投资理财类",
  "相似案例": "案例1:2023年1月18日榆次区公安局刑警四中队接到曾明报案称：1月17日曾明在家中打游戏有个陌生人联系其，说加入群聊可以交易游戏称号，曾明在指引下加入群聊，刚进群管理员就提醒其与另一个陌生人说按照要求在游戏中购买指定装备就可以得到对方的游戏称号，在管理员的引诱下曾明充值"
```

图 27 数据库展示

五、数据集构建方案

该部分旨在阐述利用大型语言模型 (LLM) 生成用于对话与短信文本诈骗风险识别的 FGRC-SCD 数据集的过程，主要使用 CCL 2023 电信网络诈骗案件分类评测 [15] 中的案例进行构建。我们通过精心设计的 Prompt 生成囊括高风险诈骗文本与无风险文本的 FGRC-SCD 数据集。并通过多重有效的数据筛选机制对该数据集进行精简，形成了具有更佳评估表现的筛选数据集，以用于对话诈骗检测系统的训练与评估。

5.1 案例数据来源

5.1.1 原始数据收集

本报告的数据来源于 CCL 2023 电信网络诈骗案件分类评测的权威数据集。该数据集经由严格筛选程序，广泛涵盖了多种类型的电信网络诈骗案例，在电信诈骗研究领域

具有高度的代表性和权威性。其所涵盖的诈骗案例类型包括但不限于冒充电商物流客服类诈骗、虚假网络投资理财类诈骗等。数据集中的每一个案例均附有详尽的案情描述与诈骗手法分析，为诈骗对话的生成与风险点的识别提供了丰富的素材。同时，为确保用户隐私权益，所有案例均经过了初步的脱敏处理。

### 5.1.2 案例数据样例

数据以 json 格式存储，每一条数据具有三个属性，分别为案件编号、案情描述、案件类别。数据样例如下：

```
{
  "案件编号": 28043,
  "案情描述": "事主（女，20岁，汉族，大专文化程度，未婚，现住址：）报称2022年8月27日13时43分许在口被嫌疑人冒充快递客服以申请理赔为由诈骗3634元人民币。对方通过电话（）与事主联系，对方自称是中通快递客服称事主的快递物件丢失现需要进行理赔，事主同意后对方便让事主将资金转入对方所谓的“安全账号”内实施诈骗，事主通过网银的方式转账。事主使用的中国农业银行账号，嫌疑人信息：1、成都农村商业银行账号，收款人：；2、中国建设银行账号，收款人：。事主快递信息：中通快递，现场勘查号：。",
  "案件类别": "冒充电商物流客服类"
}
```

### 5.1.3 数据筛选与整理

在人工筛选过程中，我们观察到部分诈骗类型文本之间存在着内容相似的问题。例如，某些被归类为“虚假网络投资理财类”的诈骗案例中，实际上蕴含了“刷单返利类”的内容，这使得两者之间的界限变得模糊，不易于准确区分，还可能导致分类混淆。为了解决这个问题，我们对原有的诈骗类型进行了重新分类与调整。

具体而言，我们将“刷单返利类”合并至“虚假网络投资理财类”中，同时将“网络游戏产品虚假交易类”并入“虚假购物、服务类”。此外，我们还将“贷款、代办信用卡类”与“虚假征信类”合并为“虚假信用服务类”，并对“网络婚恋、交友类（非虚假网络投资理财类）”进行了修正，简化为“网络婚恋、交友类”。这一系列调整旨在提高分类的准确性和清晰度，以便后续对于模型的训练。

同时，为进一步维护数据的完整性，针对脱敏后数据集中的多种无意义符号，我们统一采用‘xxx’进行填充处理。这样可以在保证原始数据完整性的基础上，统一敏感信息的填充形式，便于后续根据案例生成数据时对其进行补全。

## 5.2 数据生成方法

我们利用 CCL 2023 电信网络诈骗案件分类评测的初始数据集，考虑人与 AI 的合作，使用强大任务模型 deepseek，重新创建了更贴近任务需求的数据集；此外，我们参

考 Yue Yu 等 (2023) [16] 中描述的 AttrPrompt 方式, 在脱离原始数据集或预先训练的任务模型的情况下, 通过在提示中给予 LLM 多维、随机的属性提示, 以此作为约束来生成训练数据。

此外, 在生成数据时, 我们还采用了多轮对话系统来引导和规范模型的生成; 并采用多进程并行处理器来批量合成数据, 提高数据的生成效率。

### 5.2.1 Prompt 设计与实现

利用生成式大型语言模型 (LLM) 进行合成数据生成的 Prompting 技术, 其核心在于借助输入的文本数据 (text) 与精心设计的 prompt 来施加额外的约束条件, 旨在生成适用于特定训练任务的合成数据集。因此, 构建信息密度大且清晰简洁的 prompt 成为促使 LLM 高效生成数据的关键要素之一。

本研究设计了两套基于不同的数据生成方式的 prompt 策略:

第一套策略聚焦于已收集的原始诈骗案例数据集, 将示例案件作为整体文本约束融入 prompt 中, 以精确引导 LLM 生成与示例案件紧密相关, 且风险类型保持一致的合成文本数据;

第二套策略则是基于给定的分类任务, 在 prompt 中嵌入标签信息, 通过明确指定一系列属性作为生成约束, 在一定程度上为 LLM 提供了灵感启发, 并使 LLM 在交互过程中识别属性维度及其相应的属性值。随后, 通过属性的随机组合来生成多样化的提示, 即 Attrprompt。并且可以通过添加更多属性、或添加属性维度的方法来进一步提升生成数据的多样性。这种方法适用于黑盒 LLM, 甚至 LLM API (例如 ChatGPT), 并且不依赖于任何标记的示例, 使我们能够在资源有限的情况下高效地生成数据。在利用生成式大语言模型作为训练数据生成器的多标签分类任务中, 相较于通常用于从 LLM 查询数据的简单条件类提示 Simprompt, AttrPrompt 在所有评估指标上都优于 SimPrompt, 同时 AttrPrompt 仅利用了与 SimPrompt 关联的大语言模型查询成本的 5%[16]。

#### 策略 1: 案例描述还原文本

##### • 设计:

- 1) 对大语言模型输入进行了脱敏处理的诈骗案情描述, 定位“诈骗专家”的角色, 要求以受害者的视角还原对方的短信文本或者双方的对话内容。
- 2) 由于并行的不同步性, 我们添加了 key 为“序号”的键值对, 用于定位生成文本与对应的原诈骗数据集案例。
- 3) 生成文本中可以将一些诈骗关键词用谐音字或拼音代替, 以规避诈骗文本的筛查, 同时提高生成文本的多样性。
- 4) 强调生成对话中不允许出现链接、邮箱或者括号“()”等, 保证对话内容口语化。

- 5) 由于诈骗案情描述经过了脱敏处理，在涉及受害者名称或诈骗金额、银行卡号等敏感信息处可能是一些特殊字符，需要强调对此进行补全。
- 6) 为大语言模型提供无风险的、真实的示例短信，要求仿照示例输入的语言风格 and 情感色彩，生成符合格式的有风险及无风险文本。

- **输出要求：**

- 1) 有风险文本：要求 LLM 根据脱敏案情描述和已标注的风险类别，模拟诈骗场景，生成具有诱导和诈骗性质的短信或对话内容，并根据生成文本中可能存在风险的内容来标注风险点。
- 2) 无风险文本：生成与有风险对话背景相似但无诈骗意图的文本，确保“风险类别”为“无风险”，“风险点”为“无”。

- **示例提问：**

```
case_description = "2022年12月23日，7-1-202在家中想在网贷款，于是在网搜索并下载名为
“小度”的软件，其认为是百度公司的“度小满”借款软件。……”
case_risktype = "虚假信用服务类"
input_text = "据此案情描述进行对话生成\n案情描述：" + case_description +
              "风险类别：" + case_risktype + "序号：0"
```

- **示例生成：**

```
[
  {
    "文本": "【坐席】您好，这里是“小度”客服，我们注意到您的银行卡信息有误，导致贷款被冻结。
      请您扫描这个二维码下载“诚信通”软件，以便我们协助您解决问题。【客户】哦，好的，我扫描了。【坐席】在“诚信通”软件中，您会看到一个“银监会”公告，指出您涉嫌骗贷，需要缴纳15000元认证金。请您按照指示操作，转账至我们提供的账户。【客户】这样啊，那我转账后，贷款会解冻吗？【坐席】是的，转账成功后，我们会立即处理您的贷款，并会发放45000元。【客户】好的，我已经转了。【坐席】感谢您的配合，但系统显示再次冻结。您需要再缴纳45000元解冻费。【客户】什么？还要交钱？我感觉不对劲，我要报警。",
    "风险点": "虚假公告、诱导转账、重复缴费",
    "风险类别": "虚假信用服务类"
  },
  {
    "文本": "【坐席】您好，这里是“小度”客服，我们注意到您的贷款申请遇到了一些问题。为了更好地帮助您，请下载“诚信通”软件，这样可以更有效地沟通。【客户】好的，我已经下载了。【坐席】在“诚信通”软件中，我们会详细解释您的贷款流程，并确保您的银行卡信息正确无误。请您按照软件内的指示操作。【客户】好的，我会仔细查看并正确操作的。【坐席】如果您在操作过程中有任何疑问，随时可以通过软件内的联系方式与我们沟通。我们致力于为您提供安全和便捷的服务。【客户】好的，谢谢你们的帮助。",
    "风险点": "无",
    "风险类别": "无风险"
  }
]
```

## 策略 2: 属性提示定制诈骗文本

### • 设计:

- 1) 根据诈骗文本的特征,设计 4 个属性提示,分别是诈骗场景、诈骗方式、受害群体和诈骗犯冒充的身份。
- 2) 为了防止出现属性之间出现语义不相关的情况,分别建立“victim-scene”与“scene-criminal”两个属性匹配字典。选取每条文本的属性时,首先从 risk-victim 列表中进行受害者群体的随机选择,然后再从字典中先后随机选择与已选属性语义相符的诈骗场景和诈骗犯冒充身份两个属性。由于诈骗方式几乎与其他属性都兼容,因此也可以从 risk-way 列表中随机选择。
- 3) 生成文本中可以将一些诈骗关键词用谐音字或拼音代替,以规避诈骗文本的筛查,同时提高生成文本的多样性。
- 4) 强调生成对话中不允许出现链接、邮箱或者括号“()”等,保证对话内容口语化。
- 5) 将问题中提前嵌入的标签信息替换为随机选择的属性,要求仿照示例输出的语言风格和情感色彩,动态生成多样化、定制化的诈骗文本,输出符合格式的有风险及无风险文本各一条。

### • 输出要求:

- 1) 有风险对话:要求根据给定的诈骗属性种子,模拟诈骗场景,生成具有诱导或诈骗性质的文本,并根据生成文本中可能存在风险的内容来标注风险点。
- 2) 无风险对话:生成与有风险对话背景相似但无诈骗意图的文本,确保“风险类别”为“无风险”,“风险点”为“无”。

### • 示例提问:

```
question = "现在给你一个诈骗场景为: '<risk_scene>', 要求你使用 '<risk_way>' 的方法, 冒充<risk_criminal>对<risk_victim>群体进行诈骗。"
input_text = question.replace("<risk_scene>","银行")
input_text = input_text.replace("<risk_way>","提供个人信息")
input_text = input_text.replace("<risk_criminal>","银行员工")
input_text = input_text.replace("<risk_victim>","消费者群体")
```

### • 示例生成:

```
[
  {
    "文本": "【坐席】李华用户您好,我是XX银行客服小李,您的账户近期有异常登录记录,为确保资金安全,请尽快提供身份证号和银行卡号后四位进行验证。【客户】嗯,好的,身份证号是123456789012345,银行卡号后四位是6789。【坐席】收到,为了进一步确认,我们会给您手机发送一个验证码,请告知以完成验证。【客户】好的,验证码是2345。【坐席】感谢您的配合,账户已恢复正常。请保持警惕,勿向他人透露个人信息。",
    "风险点": "提供个人信息、告知验证码",
```

```

    "风险类别": "冒充电商物流客服类"
  },
  {
    "文本": "【坐席】亲爱的XX银行用户，为了保障您的资金安全，我们建议您定期更改密码并检查账户安全设置。记住，不要随意向他人透露个人信息哦！如有任何疑问，欢迎随时联系我们。【客户】好的，谢谢提醒。【坐席】不客气，我们一直在努力为您提供更安全、便捷的金融服务。祝您生活愉快！",
    "风险点": "无",
    "风险类别": "无风险"
  }
]

```

### 5.2.2 多轮对话引导

为了优化大型语言模型（LLM）对我们需求的理解能力，并促使其生成更接近于任务需求的文本及对话数据，我们精心构建了一套多轮对话的输入输出示例机制，旨在实现与大语言模型更为高效、精准的交互与沟通。该机制基于前几轮的引导性对话，通过逐步累积上下文信息，最终在最后一轮对话中引导 LLM 生成我们所需的数据文本内容。此机制确保了 LLM 在输出时能够深刻理解 prompt 中我们所给予属性的本质内涵，并生成既符合人类逻辑又满足特定输出格式要求的对话内容。

#### 多轮对话引导流程：

- 1) **初始化场景**：确定对话的初始状态和目标（system）。提供一个简短的背景描述作为初始输入，确定对话的主题或意图。
- 2) **模拟对话**：向大模型输入多个消息对象，并对这些消息对象进行角色分配，通过消息键值指定消息的发送者角色，这样模型可以更好地理解对话的结构和上下文，从而生成更合适的响应。模拟用户输入内容（user）为案情描述（策略 1）或诈骗属性种子（策略 2）；模拟大语言模型（LLM）响应内容（assistant）为满足逻辑与输出格式要求的、有风险和无风险文本内容各一条。这些文本带有一定的情感色彩和语言风格，由输出示例库随机选出，丰富生成文本的多样性。
- 3) **生成目标文本**：在模拟对话的最后一轮中，向大语言模型（LLM）输入真正需要的提问内容，并由 LLM 生成两段目标短信或对话：一段是有风险短信或对话，模拟诈骗者诱导受害者提供敏感信息；另一段是无风险文本，模拟正常客服与用户的交流。在模拟多轮对话的结构和上下文后，模型在生成响应时考虑到之前的对话内容，从而能够生成更符合任务需求的目标文本对话。
- 4) **反馈与调整**：若生成的对话内容与预期目标存在偏差，或出现逻辑不连贯的情况，我们可通过对当前生成内容进行评估与反馈，进而调整示例对话的构成，从而引导模型进行针对性的修正，以确保最终生成的文本能够更加精准地契合既定的目标需求。




图 28 多轮对话引导示例

### 5.2.3 多进程并行调用

我们利用 `ProcessPoolExecutor` 建立了多进程并行处理器，实现了合成数据的批量生成，从而加快任务的执行速度。通过提交任务、并行执行任务和获取任务结果的方式，完成了数据的生成和数据正确格式的提取。同时，在代码运行过程中使用了 `tqdm` 来提供进度条显示，便于实时监控处理进度，确保生成的对话质量符合预期。

## 5.3 数据评估

为了验证生成数据集是否具有足够的可靠性和有效性，确保模型训练结果和分析的准确性和可靠性，我们从数据多样性、任务相关度以及人类偏好评分三个方面对生成数据集的质量进行量化和评估。[17]

### 5.3.1 数据多样性

数据多样性的量化主要采用词频分布统计和样本相关性计算。[18]

#### 词频分布统计

词频是指特定词语在文本数据中出现的频次。词频的分布一定程度上可以反映文本数据的主题和信息密度。如果一个文本数据集中，某些词汇的词频过高，其他词汇的词频过低，那么我们认为这个数据集的多样性较差：因为这说明该文本数据集中的数据在主题表达上有明显的侧重，数据携带的信息也有所重复；相反，如果一个文本数据集的词频分布相对均匀，那么它的多样性可能更高。

我们使用中文自然语言处理分词库 jieba，将每条文本数据拆分成语义明确的中文词汇，过滤掉含有字母、数字、标点符号和特殊符号的词汇以及单字。然后通过 collections.Counter 进行词频统计，再使用停用词词典对分词和词频统计的结果进行清洗，得到文本中各词汇的频次分布情况。

词频统计的结果具有明显的长尾数据特征。长尾数据指的是低频词汇的累积频率在整体中占据了较大比例，但单个词汇的频率很低。为了避免长尾数据过多导致图像上的信息难以辨识或排布混乱，集中展示两个数据集中核心主题和关键词汇的重复情况，我们选择仅绘制前 300 个最大词频的条形图。




图 29 词频最高的 300 个词的词频分布

可以看出，相较于由案例描述还原文本生成的数据集，用属性提示定制诈骗文本的数据集在词频分布上更均匀。因此，后者在该项指标上表现出了更好的多样性。

## 样本相关性

在这一部分，我们使用文本编码模型 bge-large-zh-v1.5[19]，生成文本数据的嵌入向量，用以实现样本相关性相关指标的计算。

- 余弦相似度

$$\text{similarity}(x, y) = \frac{x \cdot y}{|x||y|} = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$

其中， $x$  和  $y$  是两个向量， $n$  是向量的维度， $x_i$  和  $y_i$  分别是向量  $x$  和  $y$  的第  $i$  个元素， $x \cdot y$  表示向量的内积， $|x|$  和  $|y|$  分别表示向量  $x$  和  $y$  的长度（或模）。

余弦相似度用于量化两个样本（以向量形式表示）之间的相似程度。当余弦相似度接近 1 时，表示两个样本非常相似；当余弦相似度接近 -1 时，表示两个样本在方

向上完全相反；当余弦相似度为 0 时，表示两个样本正交，即它们之间没有线性相关性。余弦相似度可以通过线性相关性来间接评估样本多样性。在一个样本集中，如果所有样本之间的余弦相似度都很高，那么可以认为这个样本集的多样性较低；反之可以认为这个样本集的多样性较高。

- 样本距离（欧氏距离）

$$d_{jk} = \sqrt{\sum_{i=1}^n (x_{ij} - x_{ik})^2}$$

其中， $d_{jk}$  表示样本  $j$  和样本  $k$  之间的欧氏距离， $x_{ij}$  和  $x_{ik}$  分别表示样本  $j$  和样本  $k$  在第  $i$  个特征上的值， $n$  是特征的总数。欧氏距离越小，说明两个样本在特征空间中的位置越接近，即它们的特征向量越相似，从而反映出样本间的多样性较低。相反，欧氏距离越大，则样本间的差异越大，多样性越高。

### 5.3.2 任务相关度

为了验证生成数据集是否有效地覆盖了研究问题的关键信息，我们使用 BGE-Reranker-large 模型 [19] 的 compute-score 方法量化生成数据集与研究问题之间的相关度。模型通过深入理解查询语句（用自然语言描述的研究问题）的上下文和语义，计算生成数据的相关度分数。

### 5.3.3 人类偏好评分

在本研究中，我们使用 InternLM2-7B-Reward 模型 [20] 的 get-scores 方法，通过计算数据集的平均人类偏好评分来评价生成文本的质量，包括内容的相关性、连贯性、创新性以及是否符合人类价值观等。

## 5.4 数据筛选

为了提高生成数据的质量，我们从数据多样性、数据与任务的相关性和人类偏好评分几个方面，基于包括余弦相似度、欧氏距离、问题相关度和人类偏好评分等四个量化指标来筛选数据。

对于余弦相似度和欧氏距离两个指标，我们通过如下两种方法进行数据筛选：

- 方法 1 基于行和矩阵相加的挑选方法
  - 1) 计算指标：对给定的  $n$  条文本数据，编码生成其嵌入向量并计算它们两两之间的指标，得到一个  $n \times n$  的矩阵。
  - 2) 逐行相加：将指标矩阵的每一行进行相加，得到一个包含  $n$  个元素的向量，表示每条数据与其他所有数据的指标之和。

3) 选择数据：按设定好的筛选比例选取这个向量中优化指标表现最佳的数据作为最终数据集。

• 方法 2 基于最值选择的挑选方法

- 1) 计算指标：同样，利用模型编码生成嵌入向量后两两计算  $n$  条数据之间的量化指标，得到指标矩阵。
- 2) 逐个选取：根据优化方向从指标矩阵中选择最值，按照行列索引将生成该最值的两条数据加入筛选数据集，并且将这两条数据参与构成的所有元素，即最值所在的行与列的所有数据全部排除。
- 3) 重复选择：继续选择次大值或次小值，重复上一步，直到筛选数据集的大小到达设定好的筛选比例。

以属性提示定制化生成的诈骗对话数据集为例，分别采用上述两种方法来筛选余弦相似度上表现较好的数据形成筛选数据集，并测试两组筛选后的数据集在这一指标上的表现，将筛选比例设置为 40%。

**表 4 两组筛选数据集的余弦相似度**

| 类别          | 基于行和矩阵相加筛选 | 基于最值选择筛选 | 差值 <sup>1</sup> |
|-------------|------------|----------|-----------------|
| 冒充电商物流客服类   | 0.7449     | 0.6718   | -0.0731         |
| 虚假网络投资理财类   | 0.7565     | 0.7437   | -0.0128         |
| 虚假信用服务类     | 0.7643     | 0.7425   | -0.0218         |
| 虚假购物、服务类    | 0.7197     | 0.6488   | -0.0709         |
| 冒充公检法及政府机关类 | 0.7577     | 0.7152   | -0.0425         |
| 冒充领导、熟人类    | 0.7315     | 0.7097   | -0.0218         |
| 网络婚恋、交友类    | 0.7861     | 0.7846   | -0.0015         |
| 冒充军警购物类诈骗   | 0.8203     | 0.7968   | -0.0235         |
| 网黑案件        | 0.7704     | 0.7662   | -0.0042         |
| 无风险         | 0.7249     | 0.7078   | -0.0171         |
| 所有类型        | 0.7192     | 0.7063   | -0.0129         |

<sup>1</sup> 差值 = 基于最值选择筛选 - 基于行和矩阵相加筛选

由差值一列可以直观看出，基于最值选择的筛选数据集小于基于行和矩阵相加的筛选数据集的余弦相似度。根据 5.3.1 中的分析，基于最值选择的筛选数据集在这一指标上表现更佳。因此，我们认为基于最值选择的挑选方法（方法 2）是一种更高效、更精准的数据筛选方法，并将该方法应用于原始数据集依据余弦相似度和欧氏距离进行的筛选过程。

而**任务相关度**和**人类偏好评分**都是正向指标，可以直接对原始数据集中的各条数据

进行计算，然后选取其高分位数数据作为筛选数据集。

经过上述多个指标的逐层优化筛选（每一层的筛选比例均设定为 50%），得到最终的筛选数据集。再对筛选数据集进行各个指标的测评，并与原始数据集进行比较。

表 5 短信生成数据集筛选前后的评价结果比较

| 数据集      |             | 原始数据集         |               | 筛选数据集         |               |
|----------|-------------|---------------|---------------|---------------|---------------|
| 数据评估指标   |             | 案例生成方式        | 属性提示生成方式      | 案例生成方式        | 属性提示生成方式      |
| 余弦相似度 ↓  | 所有类别        | 0.7149        | <b>0.6943</b> | 0.7041        | <b>0.6704</b> |
|          | 冒充电商物流客服类   | 0.7542        | <b>0.6981</b> | 0.7606        | <b>0.7331</b> |
|          | 虚假网络投资理财类   | 0.7967        | <b>0.7120</b> | 0.8029        | <b>0.7108</b> |
|          | 虚假信用服务类     | 0.7840        | <b>0.7050</b> | 0.7738        | <b>0.7010</b> |
|          | 虚假购物、服务类    | 0.7088        | <b>0.6931</b> | 0.6879        | <b>0.6672</b> |
|          | 冒充公检法及政府机关类 | 0.7979        | <b>0.7088</b> | 0.7835        | <b>0.6935</b> |
|          | 冒充领导、熟人类    | 0.7765        | <b>0.7063</b> | 0.7540        | <b>0.7132</b> |
|          | 网络婚恋、交友类    | 0.7469        | <b>0.6972</b> | 0.7904        | <b>0.7383</b> |
|          | 冒充军警购物类诈骗   | 0.8091        | <b>0.6913</b> | <b>0.7877</b> | 0.7942        |
|          | 网黑案件        | 0.8019        | <b>0.6989</b> | 0.8847        | <b>0.7993</b> |
|          | 无风险         | 0.7231        | <b>0.6965</b> | 0.7029        | <b>0.6758</b> |
| 欧氏距离 ↑   | 所有类别        | 0.6968        | <b>0.7184</b> | 0.7063        | <b>0.7413</b> |
|          | 冒充电商物流客服类   | 0.6544        | <b>0.7148</b> | 0.7251        | <b>0.7445</b> |
|          | 虚假网络投资理财类   | 0.5992        | <b>0.7004</b> | 0.6191        | <b>0.7195</b> |
|          | 虚假信用服务类     | 0.6186        | <b>0.7077</b> | 0.6549        | <b>0.6986</b> |
|          | 虚假购物、服务类    | 0.7037        | <b>0.7196</b> | 0.6050        | <b>0.6736</b> |
|          | 冒充公检法及政府机关类 | 0.5961        | <b>0.7034</b> | <b>0.6136</b> | 0.6041        |
|          | 冒充领导、熟人类    | 0.6251        | <b>0.7061</b> | 0.4655        | <b>0.6005</b> |
|          | 网络婚恋、交友类    | 0.6617        | <b>0.7157</b> | 0.7099        | <b>0.7365</b> |
|          | 冒充军警购物类诈骗   | 0.5812        | <b>0.7214</b> | 0.6439        | <b>0.6773</b> |
|          | 网黑案件        | 0.5912        | <b>0.7139</b> | 0.5921        | <b>0.7023</b> |
|          | 无风险         | 0.6875        | <b>0.7161</b> | 0.6317        | <b>0.7112</b> |
| 任务相关性 ↑  |             | <b>0.5665</b> | 0.5159        | <b>0.7775</b> | 0.7245        |
| 人类偏好评分 ↑ |             | <b>1.5534</b> | 0.8722        | <b>1.9457</b> | 1.5478        |

表 6 对话生成数据集筛选前后的评价结果比较

| 数据集      |             | 原始数据集         |               | 筛选数据集         |               |
|----------|-------------|---------------|---------------|---------------|---------------|
| 数据评估指标   |             | 案例生成方式        | 属性提示生成方式      | 案例生成方式        | 属性提示生成方式      |
| 余弦相似度 ↓  | 所有类别        | 0.7910        | <b>0.7592</b> | 0.7456        | <b>0.7049</b> |
|          | 冒充电商物流客服类   | 0.8172        | <b>0.7854</b> | 0.7966        | <b>0.7583</b> |
|          | 虚假网络投资理财类   | 0.8452        | <b>0.8034</b> | 0.8134        | <b>0.7487</b> |
|          | 虚假信用服务类     | 0.8452        | <b>0.8074</b> | 0.8099        | <b>0.7799</b> |
|          | 虚假购物、服务类    | 0.7893        | <b>0.7618</b> | 0.7564        | <b>0.7238</b> |
|          | 冒充公检法及政府机关类 | 0.8678        | <b>0.7966</b> | 0.8261        | <b>0.7515</b> |
|          | 冒充领导、熟人类    | 0.8562        | <b>0.7744</b> | 0.7645        | <b>0.7525</b> |
|          | 网络婚恋、交友类    | 0.8225        | <b>0.8260</b> | 0.7660        | <b>0.7912</b> |
|          | 冒充军警购物类诈骗   | 0.8815        | <b>0.8594</b> | 0.8560        | <b>0.7843</b> |
|          | 网黑案件        | 0.8745        | <b>0.8047</b> | 0.8224        | <b>0.7756</b> |
|          | 无风险         | 0.7887        | <b>0.7672</b> | 0.7382        | <b>0.7115</b> |
| 欧氏距离 ↑   | 所有类别        | 0.6093        | <b>0.6486</b> | 0.6651        | <b>0.7085</b> |
|          | 冒充电商物流客服类   | 0.5741        | <b>0.6161</b> | 0.6018        | <b>0.6507</b> |
|          | 虚假网络投资理财类   | 0.5306        | <b>0.5913</b> | 0.5799        | <b>0.6622</b> |
|          | 虚假信用服务类     | 0.5316        | <b>0.5849</b> | 0.5851        | <b>0.6241</b> |
|          | 虚假购物、服务类    | 0.6119        | <b>0.6455</b> | 0.6532        | <b>0.6886</b> |
|          | 冒充公检法及政府机关类 | 0.4893        | <b>0.6015</b> | 0.5618        | <b>0.6587</b> |
|          | 冒充领导、熟人类    | 0.5098        | <b>0.6298</b> | 0.6416        | <b>0.6577</b> |
|          | 网络婚恋、交友类    | <b>0.5652</b> | 0.5598        | <b>0.6416</b> | 0.6099        |
|          | 冒充军警购物类诈骗   | 0.4664        | <b>0.5061</b> | 0.5140        | <b>0.6183</b> |
|          | 网黑案件        | 0.4776        | <b>0.5910</b> | 0.5653        | <b>0.5938</b> |
|          | 无风险         | 0.6122        | <b>0.6387</b> | 0.6737        | <b>0.7021</b> |
| 任务相关性 ↑  |             | <b>0.5860</b> | 0.5577        | <b>0.7704</b> | 0.7498        |
| 人类偏好评分 ↑ |             | 1.1921        | <b>1.5272</b> | 1.7836        | <b>1.9586</b> |

经过逐层筛选，双生成方式的短信与对话数据集均在多样性、任务相关度、人类偏好评分等三个维度上有所提高。可见，多维度多层次的数据筛选方法对于提高生成数据质量有着显著效果。

此外，对比两种生成方式的文本数据，无论筛选前后，由属性提示生成的数据集在余弦相似度和欧氏距离这两个代表数据多样性的指标上的表现均优于案例生成的数据集；但在平均任务相关度方面不如案例生成的数据集。在人类偏好评分方面的测评，则

表现出了短信和对话这两种不同文本形式的差异：在短信数据集上，由案例还原生成的数据集优于由属性提示生成的数据集，而在对话数据集上，则是后者更满足人类偏好。

## 六、系统测试报告

### 6.1 伪造音频检测

自有数据集 ACG 的构建方式如下：

由 4554 条通过 ChatTTS 生成的伪造音频、376 条通过 GPT-SoVITS 生成的伪造音频数据以及 4388 条 Codecfake 数据集中真实音频数据构成。

表 7 伪造音频检测

|                       | Name | acc   | precision | recall | f1    |
|-----------------------|------|-------|-----------|--------|-------|
| Shared datasets       | FoR  | 98.83 | 98.36     | 96     | 97.17 |
| Self-managed datasets | ACG  | 91.23 | 94.21     | 86.71  | 90.30 |

### 6.2 合成图片检测

对于合成图片检测，我们采用了开源模型 UniversalFakeDetect，该模型在不同生成方式的数据集上表现如下：

表 8 合成图像检测

| Detection method    | Variant | Generative Adversarial Networks |          |        |          |        |         | Deep fakes | Low level vision |       |
|---------------------|---------|---------------------------------|----------|--------|----------|--------|---------|------------|------------------|-------|
|                     |         | ProGAN                          | CycleGAN | BigGAN | StyleGAN | GauGAN | StarGAN |            | SITD             | SAN   |
| UniversalFakeDetect | LC      | 100.0                           | 98.50    | 94.50  | 82.00    | 99.50  | 97.00   | 66.60      | 63.00            | 57.50 |

| Perceptual loss |       | Guided | LDM      |           |          | Glide |       |       | DALL-E | Total        |
|-----------------|-------|--------|----------|-----------|----------|-------|-------|-------|--------|--------------|
| CRN             | IMLE  |        | 200steps | 200w/ CFG | 100steps | 10027 | 5027  | 10010 |        | Avg-acc      |
| 59.50           | 72.00 | 70.03  | 94.19    | 73.76     | 94.36    | 79.07 | 79.85 | 78.14 | 86.78  | <b>81.38</b> |

### 6.3 合成人脸检测

我们使用专门的合成人脸数据集 DFFD 进行测试，发现 UniversalFakeDetect 在该数据集上的准确率不高。为提升其性能，我们利用 DFFD 数据集对 UniversalFakeDetect 进

行了微调。DFFD 数据集包含多种不同生成方式的合成人脸数据，最终微调后的模型在这些数据集上的表现如下：

表 9 合成人脸检测

| datasets | faceapp | ffhq | poggan_v1 | poggan_v2 | stargan | stylegan_celeba | stylegan_ffhq | total_avg |
|----------|---------|------|-----------|-----------|---------|-----------------|---------------|-----------|
| acc      | 87.9    | 97.9 | 99.3      | 99.9      | 99.7    | 99.7            | 91.4          | 96.54     |

| dataset | precision | recall | f1    | acc  |
|---------|-----------|--------|-------|------|
| DFFD    | 97.76     | 95.8   | 96.77 | 96.8 |

6.4 视频换脸检测

视频换脸模型 VideoFACT 在数据集下检测的各项指标如下；

表 10 视频换脸检测

| name     | ACC   | precision | recall | F1    |
|----------|-------|-----------|--------|-------|
| DFMINST+ | 0.851 | 0.863     | 0.798  | 0.830 |

6.5 文本风险检测

我们对文本风险检测中两个关键的子任务：诈骗风险分类和风险摘要生成进行了测评。诈骗风险分类最终使用的方案是直接微调预训练 BERT 类模型，使用的基础模型为 ernie-3.0-xbase-zh，在 FGRC-SCD 训练集上训练了一个 epoch，在测试集上进行二分类（有无风险）准确率和多分类（细分诈骗类型）准确率测试。风险摘要生成任务的最终方案是在 FGRC-SCD 数据集上对大语言模型 llama3-chat-chinese-8B 通过 LoRA 进行指令微调（风险分类任务），使用 1-shot 设置进行推理，并使用 InternLM-7B-Reward 对摘要质量进行测评。最终结果如下，风险摘要质量测评中的差值基准为不进行微调的大模型在同设置下的结果。

表 11 文本细粒度分类与风险摘要质量测评

| dataset/metric   | 十分类（诈骗细分类别） | 风险摘要质量测评     |
|------------------|-------------|--------------|
| FGRC-SCD(sms)    | 94.9        | 1.66 (+0.56) |
| FGRC-SCD(dialog) | 88.0        | 1.92 (+1.10) |

表 12 文本风险检测

| dataset          | acc  | precision | recall | f1    |
|------------------|------|-----------|--------|-------|
| FGRC-SCD(sms)    | 99.7 | 97.54     | 99.25  | 98.31 |
| FGRC-SCD(dialog) | 97.3 | 95.74     | 99     | 97.32 |

## 6.6 吞吐率与延迟检测

系统的吞吐率与延迟测试结果如下 (机器环境: 单卡 A800 80G):

表 13 系统吞吐率

| Type       | 不含图像的请求   | 含图像的请求    |
|------------|-----------|-----------|
| Throughput | 9.64req/s | 5.60req/s |

表 14 系统首 Token 延迟

| Type    | 不含图像的请求 | 含图像的请求  |
|---------|---------|---------|
| Latency | 0.0276s | 0.5398s |

对于视频的请求, 1 分钟左右的视频处理时间为: 13.42s。

## 6.7 MMRASE 基准

本项目构建了一个开源多模态多粒度风险内容检测基准 (Multimodal Multilevel Risk Analysis and Summary Evaluation Benchmark, MMRASE Benchmark), 包括检测任务, 细

粒度分类任务和风险摘要生成任务。在检测任务上，我们采用加权的准确率、召回率、F1-score 对我们的多模态风险内容检测平台进行测评。根据每种数据模态的重要性和出现频率，我们对音频、文本、图像和视频分别赋予不同的权重，确保在综合评分时，各模态对最终结果的贡献合理。

1) 设定模态权重：

- 伪造音频检测 (Audio) :  $w_{\text{audio}} = 0.2$
- 合成人脸检测 (Face) :  $w_{\text{face}} = 0.2$
- 视频伪脸检测 (Video) :  $w_{\text{video}} = 0.2$
- 文本风险检测 (Text) :  $w_{\text{text}} = 0.4$

2) 设定错误类型权重：

在细粒度风险分类任务上，我们采用分类准确率作为指标。在风险摘要生成任务上，我们使用奖励模型 Internlm2-7b-reward 对摘要质量进行测评，并计算在我们的方法与直接使用大模型进行推理的性能差异。根据以上评估标准，结合系统测试报告中的数据，综合得到最终的 MMRASE 基准分数如下。

表 15 各模态的加权准确率以及最终的 MMRASE 基准分数

| 模态     | 权重  | 加权准确率  | 加权精确率  | 加权召回率  | 加权 F1  |
|--------|-----|--------|--------|--------|--------|
| 伪造音频检测 | 0.2 | 0.9503 | 0.9629 | 0.9136 | 0.9374 |
| 合成人脸检测 | 0.2 | 0.968  | 0.9776 | 0.958  | 0.9677 |
| 视频换脸检测 | 0.2 | 0.851  | 0.863  | 0.798  | 0.830  |
| 文本风险检测 | 0.4 | 0.985  | 0.9664 | 0.9913 | 0.9782 |
| 检测任务分数 |     | 0.9271 | 0.9473 | 0.9286 | 0.9383 |

表 16 文本细粒度分类与风险摘要质量测评

| dataset/metric   | 十分类（诈骗细分类别） | 风险摘要质量测评     |
|------------------|-------------|--------------|
| FGRC-SCD(sms)    | 94.9        | 1.66 (+0.56) |
| FGRC-SCD(dialog) | 88.0        | 1.92 (+1.10) |

## 七、创新点

本项目在系统设计、数据集构建、策略开发与大模型技术应用等方面具有显著的创新性。

### 7.1 系统设计

本项目充分考虑了风险内容的特点，即风险内容的形式与含义都随时间快速变化，这意味着一个实用的内容风险检测系统必然需要频繁更新和进化，拥有更强的时效性，以适应越来越复杂、隐蔽的风险内容，故我们在设计时把系统的可拓展性与持续进化能力放在了相当高的位置。

**强可拓展性** 我们使用微服务架构，将系统构建在多个子服务上，这些服务可以互相通信，又具有较高的独立性。这使得系统：

- 1) 可以方便地根据预算、算力、是否有本地化部署需求等要素更换不同大模型或大模型 API。
- 2) 可以在几乎不改动原有代码的前提下通过增添新的子服务来支持新功能和新的输入数据类型。
- 3) 可以通过将不同子服务部署到多张显卡、多个节点、多台实例上，或是在多个实例上使用多个相同子服务来均摊负载等方式来实现横向拓展。

**持续进化能力** 本系统的另一个亮点是具有较强的持续进化能力，主要体现在两个层面：

- 1) **非训练更新**：对于大模型，主要通过上下文学习、多轮对话引导、检索增强生成等非训练技术来提高性能，因此可以通过更换提示词、更改示例、向风险案例库中增加新的、典型的案例等方式来以极低成本提高模型在新型风险内容上的检测、识别与分析能力，从而大大提高系统在有限预算下的时效性。
- 2) **训练数据采集与系统迭代**：系统上线后，我们将在用户允许的前提下向数据库中存储脱敏的风险输入及对应的系统输出。我们将以固定周期将数据库中存储的数据进行清洗、筛选和归类，更新风险案例库与训练数据集。风险案例库将用于检索增强生成、为多轮对话引导提供示例和实现相似案例检索功能。训练数据集可用于系统中各分类器的持续训练，并可通过离线推理生成多个输出，通过人工排序或 reward model 打分等方式形成反馈数据，从而通过 DPO 等 RLHF 方法进一步提高系统的风险分析能力。

## 7.2 数据集构建

传统的研究往往聚焦于系统或算法的测评，导致技术发展或功能拓展受制于数据集。而本项目则对数据集的构建也给予了重点关注。我们在进行数据集构建时采用了两种不同的生成方式，并且设计了一套基于多项质量评估指标的高效数据筛选机制，将经过筛选的数据用于训练和评估对话诈骗检测系统。

### 1) 利用大模型赋能数据合成

相比于仅通过爬取、筛选现有数据来构建数据集的传统方法，本项目创新性地采用了大模型合成技术。具体而言，我们采用了案例描述还原文本和属性提示定制诈骗文本两种生成方式，不仅丰富了数据集的规模和多样性，使数据具有较强的时效性和任务相关性，还避免了受制于数据的可获得性和隐私保护等问题。

### 2) 基于模型的数据集质量测评

在传统的测评数据的过程中，研究者通常需要根据具体任务和数据集的特点设计打分标准，按照打分标准人为评估数据质量。而本项目在数据集构建过程中使用了嵌入模型、重排模型和奖励模型等预训练模型来进行数据测评和筛选。这些模型原本多用于自然语言处理、信息检索、强化学习等领域，并非专为数据测评而设计。但我们创造性地对其进行了间接利用与高效整合，实现了对数据集质量的多维度评估。这种评估方法不仅高效便捷，充分利用了预训练模型的泛化能力来提高评估过程的自动化程度，而且有效减少了人工干预和主观判断对数据集质量测评的影响，避免了模型训练过程中多次迭代和调试带来的时间精力开销。

## 7.3 策略开发

本项目采用自顶向下的组合策略进行开发，作为整体开发策略的核心。具体包括以下几个方面：

- 1) **模块化设计**: 平台的各个功能模块（如图像识别、文本分析、风险评估等）被独立设计和开发，以便于后期的维护和扩展。每个模块内部使用自顶向下的设计原则，确保从整体到细节的逐步实现。
- 2) **多模态融合**: 结合图像、文本、语音等多模态数据，利用先进的融合技术实现多源信息的综合分析。通过跨模态的特征提取和融合，增强平台对复杂风险内容的识别能力。
- 3) **算法优化**: 在模型训练和推理阶段，针对不同的数据类型和应用场景，选择和优化最佳的深度学习算法。通过实验对比，找出最适合的模型结构和参数设置，提高模型的准确性和效率。

这种自顶向下的组合策略，确保了平台的开发过程既系统化又灵活化，能够快速响应不同用户和场景的需求，提供高效、精准的多模态风险内容识别服务。

## 7.4 大模型技术应用

与传统的风险识别项目不同，本项目跳出了传统的数据收集与人工标注-模型训练-难例分析的循环，充分利用现代大模型充沛的知识与强大的推理能力，使用非训练技术（如上下文学习）和高效微调技术大大提高数据利用效率，使用 awq 技术减小模型显存、加快推理速度。为充分激发了大模型在各任务上的潜力，我们在微调、推理、合成数据等环节引入了大量现代大模型技术：

- 1) **上下文学习**：我们通过将难例样本、典型样本作为示例，通过多轮对话形式，引导模型从上下文中学习如何进行风险摘要与分析任务，提高了模型的指令遵循能力，也大大简化了难例分析的流程与成本。
- 2) **检索增强生成**：我们从风险数据库中检索相似案例来为用户提供分析依据，并将相似案例作为模型上下文进一步提高模型的输出质量。检索增强生成使得我们可以通过更新风险案例库对模型进行知识更新与勘误，而无需重新对模型进行训练，在谣言等时效性较强的场景下具有明显优势。
- 3) **高效参数微调**：考虑到大模型的训练成本和算力要求较高，且往往需要兼顾多个任务，我们使用 LoRA 对大模型在子任务上进行指令微调，相比全量微调节省了大量显存与计算量。在推理阶段，可通过切换 LoRA 权重或融合 LoRA 权重来提高大模型的多任务能力。
- 4) **直接偏好优化**：在内容风险识别与分析任务上，高质量的指令微调数据较少，监督微调无法大规模进行。我们对存储的用户输入进行离线推理，使用 reward model 或人类标注的方式快速获取大量人类偏好数据。利用偏好数据，我们可使用直接偏好优化来提高模型在内容风险相关领域上的输出质量，相较于传统的近端策略优化算法具有显存占用小、与高效参数微调方法兼容性好、可离线进行（无需在训练时推理）等显著优势。
- 5) **数据合成**：我们不仅将大模型用在风险识别、分类、分析、摘要等任务上，也将大模型作为数据生成器、数据增强器与数据筛选器，为系统的测评与进一步训练提供了大量高质量合成数据，从而间接将大模型中的大量任务相关知识蒸馏到更为高效的专用任务小模型上。
- 6) **AWQ 量化方法**：为了应对企业在计算资源受限环境下的推理需求，我们采用了 AWQ (Activation Weight Quantization) 量化方法，对平台构建中使用的各类大型语言模型 (LLM) 和视觉语言模型 (VLM) 进行了深度量化处理。通过这一方法，我们显著压缩了模型的存储需求，并提升模型在低算力设备上的推理效率。具体实现中，我们将模型的权重和激活值精确量化到 INT4 精度，使得模型参数在保持原有计算精度的前提下，达到约 8 倍的存储压缩率。同时模型的推理速度也提高了 3.2-3.3 倍。这种优化使得模型在边缘设备、移动设备等资源有限的环境中能够高效运行，不仅提高了推理速度，还大幅降低了内存占用，为企业在多种应用场景中提供了灵活且低

成本的部署选择。

## 八、实用性和应用前景

近年来，我国电信网络诈骗活动猖獗，已成为影响人民群众安全感和幸福感的一个巨大的社会公害。根据党中央、国务院对防范治理电信网络诈骗工作有关指示的要求及工业和信息化部门的系列工作部署，信息通信行业和相关单位企业在工信部网安局的指导下，将人工智能等新技术广泛应用于防范治理电信网络诈骗的建设中，并取得了阶段性的明显效果。因此，本项目借助人工智能技术所开发出的多模态风险内容检测与分析平台，在电信网络诈骗防范治理领域展示了广泛的实用性和应用前景：

### 8.1 应用前景

#### 1) 诈骗信息审核过滤

诈骗信息涵盖了诸如诈骗文本、诈骗图片以及诈骗音视频等多种形式。在这些中，以诈骗短信为代表的文本信息是最早且最为显著的诈骗类型。由于其成本低廉且覆盖范围广泛，成为许多诈骗分子的首选工具。与此同时，依赖社交网络平台传播的诈骗图片和伪造音视频等形式更为复杂，通过人工换脸和虚假音频合成等技术手段，能够伪装成受害者的亲朋好友，进而使用多种预设话术逐步实施诈骗行为。这些依赖人工智能技术实施的诈骗行为，也需要相应的人工智能来进行识别和预防。因此，我们的平台致力于对网络上各种形式信息进行实时分析，评估信息的可靠性和风险性，及早辨识出涉嫌诈骗或伪造的内容。我们项目旨在及时扼杀对公众有害的信息源头，有效避免公众因此受骗，进而保护其财产安全。

#### 2) 风险网址拦截

风险网址是指那些含有虚假信息、诈骗引诱或色情内容的网站，目前被诈骗分子广泛利用以窃取用户个人信息或进行网络勒索诈骗。我们的平台通过爬取网页文字、图片和音频内容，并进行全面检测，以判断网站是否存在潜在风险，并及时向用户提供警示。在授权范围内，我们还能够对风险网站进行拦截处理。因此，我们的平台能够有效识别和评估风险网址，有力防范用户在浏览过程中遭受各类网络安全威胁。通过持续的技术更新和优化，我们能够及时发现并响应新出现的风险网站，迅速更新拦截策略，以确保用户始终处于安全可靠的网络环境中。此外，我们还可以与其他安全服务提供商合作，共享最新的威胁情报和安全防护策略，以提升整体网络安全的防护水平。

#### 3) 风险对话实时监测

风险对话指在社交网络平台上，用户之间的聊天内容可能涉及诱导性言论、虚假信息等情况。一些不法分子通过网络社交平台与受害者进行对话，以实施诈骗行

为，目的是窃取受害者的个人信息或财产。这种低成本的诈骗手段不仅有助于发现潜在的受害者群体，还可能导致更进一步的欺诈活动，因此成为反诈防范的重要焦点。我们的平台能够针对用户反馈的对话内容进行实时检测和分析，快速识别潜在的诈骗、欺诈或其他恶意意图。一旦发现可能存在风险的对话，我们会立即向用户发送警示信息，以帮助用户识别潜在的威胁，保障其个人信息和财产安全，尽早扼制诈骗活动的发生。用户可通过直接上传聊天记录截图的方式进行检测，无需手动输入文字，从而提升了用户的操作便捷性和体验。通过实时监测和有效应对风险对话，我们致力于建立一个更加安全可信的在线交流环境，为用户提供安全的互联网体验。

#### 4) 风险文件提前预警

风险文件是指内含诈骗或其他潜在威胁内容的多种形式文件。一些诈骗分子常利用文件形式发送虚假信息或诈骗内容，从而规避现有的多数诈骗风险检测手段。因此，我们平台开发了专门针对风险文件的检测功能，能够通过分析文件中的文本、图片等元素，判断文件是否存在风险或威胁，并及时向用户发出预警，以确保用户安全。这项功能致力于全面阻断诈骗分子通过文件传播的各种潜在诈骗手法。此外，若能与主流社交媒体合作，我们平台能够快速准确地扫描分析这些平台上的大量文件。一旦发现可疑内容，我们将立即发布警示，以保护更多用户的信息和财产安全。这种综合性的文件检测和反应机制不仅有助于防范新型欺诈手段，如恶意软件传播或网络钓鱼攻击，还能有效提升网络社区的整体安全性和信任度。这些措施展示了我们在保护用户免受欺诈和安全威胁方面的承诺和技术实力，为用户提供了一个安全可信的在线交流环境。

#### 5) 反诈知识普及

尽管当前国家政府高度重视电信网络诈骗的防范工作，并加强了对公众的警示教育活动，但诈骗分子的技术水平十分高超，其使用的手段也日益先进。许多人因对诈骗手段缺乏了解而不慎落入诈骗者的陷阱，导致个人财产损失或个人信息泄露的情况频发。而我们的平台已经开发出了“数字人”功能，允许用户通过上传音频与图片，生成伪造视频，模拟图片中的人物“说话”。未来，我们可以与反诈宣传机构展开合作，利用这一功能帮助用户亲身体验诈骗分子可能采用的伪造过程，从而提升用户的风险防范意识和警惕性，加强公众对诈骗的理解和防范能力，有效减少诈骗案件的发生率。

## 8.2 实用性

#### 1) 市场需求广泛

近年来，电信网络诈骗手段层出不穷，多模态风险内容诈骗，如伪造人脸、声音、视频等的诈骗方式，越来越难以被检测，每年被电信网络诈骗的人数仍在持续

增加。针对这种复杂多变的风险内容，我们开发的多模态风险内容识别平台能帮助用户更好地应对这种新型诈骗。

## 2) 系统部署成本低

为检测多模态风险内容，我们选取了大模型来研究和开发该平台。为了方便用户使用，我们全部选用的是 7B 大模型（拥有 70 亿参数的大模型），这类大模型规模较小，一些中小企业以及用户都可以很方便的在本地服务器上部署起来。除此之外，我们还提供了基于 Android 系统的 APP，在用户允许的情况下，可以对用户收到的短信进行风险检测。

## 3) 可维护性高

我们使用了模块化设计的策略开发方法，各个模块之间相互独立，减少了模块间的耦合，可以很方便的对其进行维护和扩展。除此之外，对于每个模块，我们将其封装成服务来使用，更加方便的进行各模块之间的通信，通过使用守护进程来监听各个服务的咋混个太，系统具有较强的鲁棒性，易于维护。

## 4) 提升用户体验

用户体验是产品是否实用一个很关键的因素。我们采用了一系列的系统加速方案以及通过流式返回输出给用户，让用户能及时得到风险内容的反馈，最大程度的降低可能的损失。

# 参考文献

- [1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks, 2021.
- [2] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models, 2023.
- [3] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision, 2022.
- [4] Feng Li, Renrui Zhang, Hao Zhang, Yuanhan Zhang, Bo Li, Wei Li, Zejun Ma, and Chunyuan Li. Llava-next-interleave: Tackling multi-image, video, and 3d in large multimodal models. [arXiv preprint arXiv:2407.07895](https://arxiv.org/abs/2407.07895), 2024.
- [5] Tai D Nguyen, Shengbang Fang, and Matthew C Stamm. Videofact: Detecting video forg-

- eries using attention, scene context, and forensic traces. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, pages 8563–8573, 2024.
- [6] Utkarsh Ojha, Yuheng Li, and Yong Jae Lee. Towards universal fake image detectors that generalize across generative models, 2024.
- [7] Davide Alessandro Coccomini, Nicola Messina, Claudio Gennaro, and Fabrizio Falchi. Combining EfficientNet and Vision Transformers for Video Deepfake Detection, page 219–229. Springer International Publishing, 2022.
- [8] Yuankun Xie, Yi Lu, Ruibo Fu, Zhengqi Wen, Zhiyong Wang, Jianhua Tao, Xin Qi, Xiaopeng Wang, Yukun Liu, Haonan Cheng, Long Ye, and Yi Sun. The codecfake dataset and countermeasures for the universally detection of deepfake audio, 2024.
- [9] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021.
- [10] Yu Sun, Shuohuan Wang, Shikun Feng, Siyu Ding, Chao Pang, Junyuan Shang, Jiaxiang Liu, Xuyi Chen, Yanbin Zhao, Yuxiang Lu, Weixin Liu, Zhihua Wu, Weibao Gong, Jianzhong Liang, Zhizhou Shang, Peng Sun, Wei Liu, Xuan Ouyang, Dianhai Yu, Hao Tian, Hua Wu, and Haifeng Wang. Ernie 3.0: Large-scale knowledge enhanced pre-training for language understanding and generation, 2021.
- [11] Mayank Kulkarni, Debanjan Mahata, Ravneet Arora, and Rajarshi Bhowmik. Learning rich representation of keyphrases from text. In Findings of the Association for Computational Linguistics: NAACL 2022, pages 891–906, Seattle, United States, July 2022. Association for Computational Linguistics.
- [12] Shangchen Zhou, Kelvin C.K. Chan, Chongyi Li, and Chen Change Loy. Towards robust blind face restoration with codebook lookup transformer. In NeurIPS, 2022.
- [13] Cong Wang, Kuan Tian, Jun Zhang, Yonghang Guan, Feng Luo, Fei Shen, Zhiwei Jiang, Qing Gu, Xiao Han, and Wei Yang. V-express: Conditional dropout for progressive training of portrait video generation. 2024.
- [14] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E. Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with pagedattention, 2023.
- [15] Chengjie Sun, Jie Ji, Boyue Shang, and Binguan Liu. CCL23-eval 任务 6 总结报告: 电信网络诈骗案件分类 (overview of CCL23-eval task 6: Telecom network fraud case

- classification). In Maosong Sun, Bing Qin, Xipeng Qiu, Jing Jiang, and Xianpei Han, editors, Proceedings of the 22nd Chinese National Conference on Computational Linguistics (Volume 3: Evaluations), pages 193–200, Harbin, China, August 2023. Chinese Information Processing Society of China.
- [16] Yue Yu, Yuchen Zhuang, Jieyu Zhang, Yu Meng, Alexander Ratner, Ranjay Krishna, Jiaming Shen, and Chao Zhang. Large language model as attributed training data generator: A tale of diversity and bias, 2023.
- [17] Xu Guo and Yiqiang Chen. Generative ai for synthetic data generation: Methods, challenges and the future, 2024.
- [18] Lin Long, Rui Wang, Ruixuan Xiao, Junbo Zhao, Xiao Ding, Gang Chen, and Haobo Wang. On llms-driven synthetic data generation, curation, and evaluation: A survey, 2024.
- [19] Shitao Xiao, Zheng Liu, Peitian Zhang, and Niklas Muennighoff. C-pack: Packaged resources to advance general chinese embedding, 2023.
- [20] Zheng Cai, Maosong Cao, Haojiong Chen, Kai Chen, Keyu Chen, Xin Chen, Xun Chen, Zehui Chen, Zhi Chen, Pei Chu, Xiaoyi Dong, Haodong Duan, Qi Fan, Zhaoye Fei, Yang Gao, Jiaye Ge, Chenya Gu, Yuzhe Gu, Tao Gui, Aijia Guo, Qipeng Guo, Conghui He, Yingfan Hu, Ting Huang, Tao Jiang, Penglong Jiao, Zhenjiang Jin, Zhikai Lei, Jiaxing Li, Jingwen Li, Linyang Li, Shuaibin Li, Wei Li, Yining Li, Hongwei Liu, Jiangning Liu, Jiawei Hong, Kaiwen Liu, Kuikun Liu, Xiaoran Liu, Chengqi Lv, Haijun Lv, Kai Lv, Li Ma, Runyuan Ma, Zerun Ma, Wenchang Ning, Linke Ouyang, Jiantao Qiu, Yuan Qu, Fukai Shang, Yunfan Shao, Demin Song, Zifan Song, Zhihao Sui, Peng Sun, Yu Sun, Huanze Tang, Bin Wang, Guoteng Wang, Jiaqi Wang, Jiayu Wang, Rui Wang, Yudong Wang, Ziyi Wang, Xingjian Wei, Qizhen Weng, Fan Wu, Yingtong Xiong, Chao Xu, Ruiliang Xu, Hang Yan, Yirong Yan, Xiaogui Yang, Haochen Ye, Huaiyuan Ying, Jia Yu, Jing Yu, Yuhang Zang, Chuyu Zhang, Li Zhang, Pan Zhang, Peng Zhang, Ruijie Zhang, Shuo Zhang, Songyang Zhang, Wenjian Zhang, Wenwei Zhang, Xingcheng Zhang, Xinyue Zhang, Hui Zhao, Qian Zhao, Xiaomeng Zhao, Fengzhe Zhou, Zaida Zhou, Jingming Zhuo, Yicheng Zou, Xipeng Qiu, Yu Qiao, and Dahua Lin. Internlm2 technical report, 2024.

## 致谢

在此，特别感谢文杰老师和李穆老师对该项目的全力支持和悉心指导。

特别感谢中国联通公司提供了这道有意义的赛题以及对我们项目提供的支持和资源，让我们更深入了解到当前社会环境下电信诈骗的高发情况以及现阶段防诈骗过程中所面临的挑战，对我们项目的成功完成提供了极大的帮助。

感谢以下项目提供的优秀代码和模型

Unichat Qwen2-VL Combining-EfficientNet-and-Vision-Transformers-for-Video-Deepfake-Detection

opennsfw2

face\_recognition

CnOCR UniversalFakeDetect

DeepFake-Audio-Detection-MFCC

ChatTTS

faster-whisper-large-v3

CodeFormer

V-Express

GPT-SoVITS

bge-reranker-v2-m3

internlm2-7b-reward

bge-large-zh-v1.5

ernie-3.0-xbase-zh

Llama3.1-8B-Chinese-Chat

Qwen2-7B-Instruct

Meta-Llama-3-8B

Meta-Llama-3.1-8B-Instruct

## A 附录：项目文档

代码仓库：<https://github.com/dodododddo/MMRiskDetection>

## 1.1 项目代码框架

```
MMRiskDetection
├─ AudioPipeline
├─ DataBuffer
├─ DataPipeline
├─ DigitalHumans
├─ FilePipeline
├─ Frontend
├─ ImagePipeline
├─ TextPipeline
├─ VideoPipeline
└─ WebPipeline
```

图 30 项目代码框架

## 1.2 Quick Start

### 2) Server for MMRiskDetection

您可以使用以下命令启动 MMRiskDetection 系统的服务端，并对各个服务的运行状态进行监控。在服务出现异常中断时，该系统将自动检测并重启相应服务，确保服务的持续可用性。

```
$ ./scripts/start_server.sh
$ ./scripts/monitor_server.sh
```

您可以通过以下命令关闭 MMRiskDetection 系统的服务端

```
$ ./scripts/stop_monitor.sh
$ ./scripts/stop_server.sh
```

### 3) Client for MMRiskDetection

你可以通过以下命令打开 MMRiskDetection 系统客户端

```
$ cd Frontend/utils
$ conda activate image
$ python MMRiskDetectionApp.py
```

### 1.2.1 VideoPipeline

你可以通过以下命令启动视频检测服务，该服务接受视频路径，并分析该视频是否是伪造的，该视频的声音是否是伪造的，该视频是否包含色情内容，视频是否含有风险行为和视频音频是否存在风险内容。

```
$ conda activate videofact
$ cd VideoPipeline
$ python server.py
```

检测命令如下：

```
$ curl -X POST "http://127.0.0.1:1927/video" -H "Content-Type: application/json"
-d '{"video_path": "path/to/your/videofile.mp4"}'
```

### 1.2.2 ImagePipeline

你可以通过以下命令启动图像检测服务，该服务接受图像路径，并分析该图像是否是合成的，该图像是否包含色情内容，提取该图像中的文字，以及图像本身是否含风险内容。

```
$ conda activate image
$ cd ImagePipeline
$ python server.py
```

你可以通过以下命令调用该服务：

```
$ conda activate image
$ cd ImagePipeline
$ python client.py
```

### 1.2.3 AudioPipeline

#### 1) Server for DeepFake-Audio-Detection-MFCC

你可以通过以下命令启动一个音频检测服务，该服务接受音频文件路径并分析该音频文件是否为伪造的。

```
$ conda activate Audio_CD
$ cd AudioPipeline/DeepFake-Audio-Detection-MFCC/
$ python server_for_audioanalyzer.py
```

检测命令如下：

```
$ curl -X POST "http://127.0.0.1:9998/audio_detection" -H "Content-Type: application/json" -d '{"audio_for_analyse_path": "path/to/your/audiofile.wav"}'
```

## 2) Server for Speech-to-text

你可以通过以下命令启动一个音频转换服务，该服务接受音频文件路径并将音频文件转换为文本。

```
$ conda activate Audio_CD
$ cd AudioPipeline/
$ python server_for_to_text.py
```

转换命令如下：

```
$ curl -X POST "http://127.0.0.1:9999/audio" -H "Content-Type: application/json" -d '{"audio_path": "/path/to/audio/file.wav"}'
```

## 1.2.4 DigitalHumans

### 1) Server for CodeFormer

```
$ conda activate codeformer
$ cd DigitalHumans/CodeFormer/
$ python server_for_FaceRestorer.py
```

通过以上步骤，用户可以启动一个图片裁剪、增强或视频增强服务，该服务使用 FastAPI 框架提供一个 RESTful API 接口，接受图片文件路径并将进行相应操作。步骤如下：

- 图片裁剪

```
curl -X POST "http://127.0.0.1:9997/Digital_face1" -H "Content-Type: application/json" -d '{
    "ImageorVideo_for_restored_path": "path/to/your/image_or_video",
    "function_Facial_rejuvenation": true,
    "function_image_enhancement": false,
    "function_video_enhancement": false
}'
```

- 图片增强

```
curl -X POST "http://127.0.0.1:9997/Digital_face1" -H "Content-Type: application/json" -d '{
    "ImageorVideo_for_restored_path": "path/to/your/image_or_video",
    "function_Facial_rejuvenation": false,
    "function_image_enhancement": true,
}
```

```
    "function_video_enhancement": false
  },
```

- 视频增强

```
curl -X POST "http://127.0.0.1:9997/Digital_face1" -H "Content-Type: application
/json" -d '{
  "ImageorVideo_for_restored_path": "path/to/your/image_or_video",
  "function_Facial_rejuvenation": false,
  "function_image_enhancement": false,
  "function_video_enhancement": true
}'
```

## 2) Server for GPT-SoVITS

```
$ conda activate GPTSoVits
$ cd DigitalHumans/GPT-SoVITS/
$ python GPT_SoVITS/sever_for_SSTGen.py
```

通过以上步骤，用户可以启动一个音色克隆服务，该服务使用 FastAPI 框架提供一个 RESTful API 接口，接受参考音频的路径以及待生成的文本并将进行音色克隆操作。生成步骤如下：

```
curl -X POST "http://127.0.0.1:9995/SSTGen" -H "Content-Type: application/json" -
d '{"ref_wav_path": "path_to_wav_file.wav", "prompt_text": "你好", "text": "这
是一个测试"}'
```

## 3) Server for V-Express

```
$ conda activate V-Express
$ cd DigitalHumans/V-Express/
$ python server_for_V-Express.py
```

通过以上步骤，用户可以启动一个视频生成服务，该服务使用 FastAPI 框架提供一个 RESTful API 接口，接受参考音频的路径以及目标人物人脸图片并将进行视频生成操作。生成步骤如下：

```
curl -X POST "http://127.0.0.1:9996/Digital_video" -H "Content-Type: application
/json" -d '{"Image_path": "path_to_image.jpg", "Audio_path": "path_to_audio.
wav", "function_A": true, "function_B": false, "function_C": false}'
```

### 1.2.5 TextPipeline

- 启动其他服务前，需要先启动 vllm 本地模型服务

```
$ conda deactivate
$ cd TextPipeline
$ python scripts/start.py --model_name unichat/llama3/qwen2
```

- 启动文本风险检测 demo

```
$ cd TextPipeline
$ python mm_demo.py
```

- 启动文本风险服务

```
$ cd TextPipeline
$ python mm_server.py
```

- 测试风险点抽取

```
$ cd TextPipeline
$ python extraction.py
$ python ext_server.py // 开启风险点抽取服务
```

- 使用 LoRA 进行指令微调

```
$ cd TextPipeline
$ python sft.py --model_path path/to/your/model
                --train_dataset_path path/to/your/train_dataset
                --eval_dataset_path path/to/your/eval_dataset
                --rank lora_rank
                --save_dir path/to/your/save_dir
```

- 测试 RAG 系统

```
$ cd TextPipeline
$ python rag.py
```

- 批量生成摘要并使用 reward 模型测试

```
$ cd TextPipeline
$ python summary.py
$ python reward.py
```