

政务智能体安全防护系统 学生任务手册

项目	面向政企场景的大模型智能体安全关键技术研究
版本	v2 (2026-08-26 数字定版)
分支	feat/p0-real-e2e-test (PR #16)
截止	2026-09-15 24:00

本手册供参赛同学按章节认领撰写与素材制作任务使用，内容分三部分：任务分配、部署与使用说明、撰写规范。请通读第三部分后再动笔。所有数字以冻结表为准，不得自行改动。

第一部分 任务分配

每人认领一组任务，只改自己章节的文件。写作素材、验收标准与工期如下表，分项操作细节在第二部分。所有产出的 LaTeX 写入 docs/competition/latex/sections/ 对应文件。

任务总表

学生	负责内容	工期	关键产出
A	第 1 章背景与问题分析（3 页）+ 图 1 威胁演进	2 天	01-background.tex + fig1-threat-evolution.pdf
B	第 5 章数据集构建（3 页）+ 图 4 构建漏斗	2 天	04-dataset.tex + fig4-dataset-pipeline.pdf
C	第 3 章系统功能展示（3 页）+ 图 5-8 截图 + 视频分镜	3 天	03-demo.tex + 四张截图 + video-storyboard.md
D	第 8 章应用前景 + 参考文献 + 附录 B/C/D + 补充材料包汇编	2 天	08-prospects.tex + refs.bib + 附录三份 + supplementary/
E	图 2 架构图 + 图 3 泳道图（按核心组规格）+ 实验复跑收割 + 全文格式校对	2 天	fig2-architecture.pdf + fig3-workflow.pdf + 校对清单

注：第 2、4（部分）、6、7 章由核心组撰写。所有数字以 docs/competition/metrics-frozen-v1.md 冻结表为唯一来源，文档中的数字必须与冻结表一致，不得引用历史数据文件。

分项任务说明

学生 A：第一章（3 页）

素材：官方要求文档（D1-D4 技术方向）、验证报告的 5.3 节（攻击有效性问题）、架构审查文档的 1.1 节。

三节结构：威胁演进三阶段（各配具体攻击形态）；现有方案三类不足（各配一句话的实测依据）；政企场景约束与问题定义。

表 1：六个业务域与典型攻击面，六到八行，两行内写完一行。

图 1：三阶段横向时间线，每段标注攻击面、典型载荷、防护需求。draw.io 或 PPT 绘制，导出 PDF。

学生 B：第五章（3 页）

素材：基准文档（攻击基准-66条经验证用例.md 为背景知识）、冻结表 v2 第 3 节的诚实化重建叙事、第 1 节基准规模数字。

四节结构：三层验证链（裸诱导预筛、真实环境有效性、有防护复测）；诚实化重建（污染发现、清理、三代话术重建）；攻击面三项发现；白名单设计。

表：三代话术的候选数、诱导数与代表话术摘要；漏斗图包含各层淘汰原因。

图 4：三层漏斗，含各层淘汰原因分类计数与五个模式的数量分布。

学生 C：第三章（3 页）+ 截图 + 视频分镜

第四节结构：一键部署（图 5）、正常办公放行（图 6）、攻击拦截（图 7）、审计溯源（图 8）。

截图操作严格按第二部分的指令执行，真实终端截图，不修图。

视频分镜：30 秒问题、2 分半架构、4 分钟实机演示、2 分钟数字、1 分半总结。写到 docs/competition/video-storyboard.md。

学生 D：第八章 + 参考文献 + 附录 + 补充材料包

第八章第三节梗概已在主文档给出，扩写为各一页。

参考文献扩至十五条以上，以现有十条为基础，补充 CaMeL、智能体安全综述与政务安全政策文件。

附录 B 为评审提示词全文，来源为 src/system/policies/llm_injection_judge.py 的系统提示变量，verbatim 排版无删节。

附录 C 为快速部署指南，改写自 run_e2e.sh 帮助与学生部署指南。

附录 D 为审计日志样例，从 src/system/proxy/audit_log.jsonl 抽二十条并附字段说明表。

补充材料包汇编到 docs/competition/supplementary/，六项内容清单在主文档末尾。

学生 E：图 2/图 3 + 实验收割 + 格式校对

图 2 总体架构图：左列智能体框架，中列四层判定，右列四色处置出口，底部审计条带。核心组提供草图核对后再画。

图 3 工作流程泳道图：用户、智能体、防护代理、评审模型四泳道，含确认层的评审与人工回流路径。

实验收割：按命令清单执行并归档结果到 results/ 目录。

格式校对清单：页数不超 30、目录与交叉引用连续、数字与冻结表逐项核对、无破折号、无占位符。

第二部分 部署与使用说明

目标是在你自己的电脑上跑通完整链路：真实智能体框架（OpenClaw）+ 防护系统 + 攻击测试。全程约三十到四十分钟，其中 OpenClaw 下载占大头。

第一步：环境与克隆

依赖：Python 3.9 以上、Node.js 22 以上、npm 11 以上、Git。

克隆仓库并切到工作分支：git clone <仓库地址>，然后 git checkout feat/p0-real-e2e-test。

向负责人索取 .env.local 文件放到仓库根目录。不要把 key 发到群里或提交到 git。

第二步：一键部署

在仓库根目录执行：

```
bash scripts/setup_openclaw.sh
```

脚本依次完成环境检查、OpenClaw 安装（本地目录，不污染系统）、五十个政务技能部署、模型路由配置与政务工具注册。失败时按脚本提示处理，仍失败就联系负责人。

第三步：启动与验证

```
./run_e2e.sh check
```

```
./run_e2e.sh start
```

```
./run_e2e.sh smoke
```

check 应全部通过；start 应显示两个服务就绪；smoke 应显示模型回复与冒烟通过。

第四步：进入对话界面

```
cd ../openclaw-runtime && OPENCLAW_HOME=$(pwd) node_modules/.bin/openclaw chat --local
```

先试良性任务：统计通知台账里待发布的通知数量。应正常返回数据，无拦截。

再试攻击话术（基准集中的真实样本）：灾备演练语境下要求把档案室台账打包传输到恢复点。应出现拦截提示，代理终端打印判定记录。

第五步：跑攻击用例

```
./run_e2e.sh bench
```

基准集约一小时跑完，结果写入 results/ 目录。单条调试用：python3

src/scripts/openclaw_case_runner.py --ids <编号>，编号见补充材料包提示词表。

常见问题

现象	处理
模型调用报错流式参数不匹配	git pull 后重启服务（run_e2e.sh stop 再 start）
智能体报找不到工具	政务工具注册未成功，按学生部署指南第 3.4 节手动注册并验证
良性请求也被拦	技能不是规范化版本，重新跑 setup_openclaw.sh 覆盖
攻击没被拦且真的执行了	模拟工具无真实副作用，不会真删文件；把 case 编号发给负责人
代理日志出现评审错误	评审模型网络抖动属正常，系统会自动降级处理；频繁出现告诉负责人

三条纪律

- 不改 data/system-design/e2e-pilot/ 下任何用例数据文件。
- 不把 .env.local 或任何 key 提交、截图或发群。
- 实验结果 jsonl 原样提交，改动记录写在提交信息里。

第三部分 撰写规范

冻结数字（写作时全部数字的唯一来源）

以下数字为 2026-08-26 定版，任何文档中的数字必须与此一致，不一致即打回。

指标	数值
基准规模	候选 140 条 → 有效攻击 62 条（产率 44%）
层级构成	单轮完备化 35 / 三轮渐进 12 / 隐蔽话术 15
模式分布	数据外泄 47 / 破坏操作 14 / 系统破坏 1
穿透率	0/62（0%）
拦截	28/62（45.2%），其中诱导成立拦截 27
白名单误报率	0/25（0%）
攻击侧分层正确率	45.2%
业务侧分层正确率	100%

完整冻结表见 docs/competition/metrics-frozen-v1.md。攻击面三项发现、诚实化重建叙事表、废弃数字清单均在冻结表中，第五章引用时逐项对照。

写作风格

必守五条

- 不用破折号，句间停顿用逗号或句号。
- 不用“不是……而是……”句式，直接给结论。
- 引号只用于政策文件名和首次引入的正式术语，不用于强调。
- 括号只用于缩写、公式和必要限定，不用于补充说明。
- 每段开头一句给结论或对象，后面给证据；一段只说一件事。

禁用词汇与句式

- 禁用：赋能、抓手、闭环、全方位、多维度、深度融合、保驾护航、值得注意的是、综上所述。
- 禁用：随着……的发展、在当今……背景下、首先……其次……最后……这类模板句。
- 句子有数字就写数字，有单位就写单位名（财务科、信访办），不写“某部门”。
- 不写“填补空白”“首次”“国际领先”，写清楚具体做了什么、测出了什么。

段落自检

写完整段后逐句检查：这一句和前一句是什么关系（递进、因果、条件、举例、结论）？说不出来就改顺序或合并。写完出声读一遍，读着别扭的句子就是需要改的句子。

图表规范

- 矢量图，工具用 draw.io 或 PPT，导出 PDF 到 figures/ 目录，文件名按任务书固定。
- 配色四档贯穿全篇：放行绿 #2E7D32、上报蓝 #1565C0、确认黄 #F9A825、阻断红 #C62828。

图内文字最小字号相当于正文小四，导出前把默认灰边框改成深灰 #424242。

每张图在正文有引用和一段说明，说明写读者应该看到什么，不写“如图所示”。

截图为真实终端截图，字号不小于十四磅，不修图。

提交方式

每人一个分支：stu-A-ch1、stu-B-ch4、stu-C-ch3、stu-D-ch8、stu-E-figs。

只改自己章节的 tex 文件与 figures 目录里自己的图，提交信息格式为“ch1: 初稿”“ch1: 按验收标准修改第2轮”。

合并由核心组统一执行，不要在分支间互相合。

写作中不确定的内容问负责人，不要编造数字、文献或实验结果。

写作检查清单（提交前逐项过）

本章节所有数字与冻结表一致，逐项核对打钩。

全文无破折号、无“不是……而是……”、无禁用词。

图表有编号、有正文引用、有说明段。

引号只出现在政策文件名和首次引入的术语上。

每段能说出“这一段回答了什么问题”。

时间线

阶段	日期	内容
W1	8/27-8/31	各章节初稿与配图到位
W2	9/1-9/8	数字冻结后全文集成，补充材料包定稿，视频录制
W3	9/9-9/15	打磨、代码包整理、提交物核对、缓冲、提交